

Apêndice A - Esperança e distribuições do zero

Uma ponte passo a passo entre a estatística descritiva do Capítulo 2 e as distribuições do Capítulo 3


Material complementar para Análise Exploratória de Dados - Cayo Oliveira

Ideia central

Este apêndice não substitui o Capítulo 3. Ele expande especialmente as seções sobre variável aleatória, esperança, variância probabilística, Bernoulli, binomial, uniforme e normal. A ordem foi reorganizada para responder primeiro às perguntas conceituais que precisam existir antes das fórmulas.

O problema pedagógico que este apêndice resolve. No Capítulo 2, a turma calcula média, variância e desvio-padrão a partir de valores que já foram observados. No Capítulo 3, surge uma mudança importante: passamos a representar *resultados que ainda podem acontecer*. Se essa mudança não for explicitada, fórmulas como $E(X)$, $p^x(1-p)^{1-x}$ ou a densidade normal parecem surgir sem história.

Aqui seguiremos a sequência:



Pergunta que precisa estar respondida

Antes de qualquer fórmula, o aluno deve conseguir responder: **qual é o fenômeno, quais resultados podem ocorrer, qual número X representa cada resultado e como a probabilidade é distribuída entre esses valores?**

A.1 Antes de falar em esperança: o que é uma distribuição?

Comece com uma situação concreta. Uma central acompanha se um chamado será **reaberto** ou **não reaberto**. Antes de observar o próximo chamado, não sabemos o resultado. Definimos:

$$X = \begin{cases} 1, & \text{se o chamado for reaberto,} \\ 0, & \text{se não for reaberto.} \end{cases}$$

Se, em casos comparáveis, estimamos uma chance de reabertura de 20%, então temos duas coisas diferentes:

- os **valores possíveis de X** : 0 e 1;
- a **probabilidade associada a cada valor**: $P(X = 0) = 0,8$ e $P(X = 1) = 0,2$.

Essa combinação é uma **distribuição de probabilidade**.

Ideia central

Uma distribuição responde: **quais valores uma variável aleatória pode assumir e como a probabilidade total de 100% é distribuída entre esses valores ou regiões?**

Discreta e contínua: por que a probabilidade é atribuída de maneira diferente?

Variável aleatória discreta. Assume valores contáveis: número de reaberturas, quantidade de defeitos, número de faltas. Podemos atribuir probabilidade diretamente a um valor:

$$p_X(x) = P(X = x), \quad \sum_x P(X = x) = 1.$$

Por exemplo, se X é o resultado de um dado honesto,


$$P(X = 3) = \frac{1}{6}.$$

Para um conjunto de valores, somamos as massas:

$$P(2 \leq X \leq 4) = P(X = 2) + P(X = 3) + P(X = 4).$$

Variável aleatória contínua. Assume, idealmente, qualquer valor em um intervalo: tempo, massa, temperatura, altura. Agora não atribuímos probabilidade positiva a cada ponto individual. Usamos uma **densidade** $f_X(x)$ e calculamos probabilidade por área:

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx.$$



Cuidado com esta confusão

No gráfico contínuo, o eixo X contém os valores possíveis da variável. O eixo Y contém **densidade**, não “probabilidade daquele ponto”. A probabilidade aparece como **área**. Por isso, em um modelo contínuo, $P(X = 5) = 0$ não significa que 5 seja impossível: um ponto isolado tem largura zero e, portanto, área zero.

A.2 Da frequência observada ao modelo de probabilidade

No Capítulo 2, frequência relativa é uma descrição dos dados:

$$\hat{p} = \frac{\text{número de ocorrências}}{\text{total observado}}.$$

Se 20 de 100 chamados comparáveis foram reabertos,

$$\hat{P}(R) = \frac{20}{100} = 0,20.$$

Essa proporção pode ser usada como uma estimativa para modelar casos futuros, desde que o processo, a população e a definição de “reabertura” permaneçam comparáveis.

Passo a passo

1. **Observe:** 20 reaberturas em 100 chamados.
2. **Resuma:** frequência relativa = 20%.
3. **Modele:** para um próximo chamado comparável, use $p \approx 0,20$ como probabilidade estimada.
4. **Decida:** pergunte o que muda se a taxa verdadeira estiver perto de 20%.

Aplicação e decisão no mundo real

Uma equipe descobre que reaberturas consomem, em média, 25 minutos adicionais de trabalho. Com taxa estimada de 20%, cada 100 chamados geram aproximadamente 20 reaberturas, ou cerca de 500 minutos adicionais. A coordenação pode decidir investir em revisão da primeira resposta, documentação ou capacidade de atendimento. A probabilidade não é a decisão: ela quantifica uma incerteza relevante para a decisão.

Variabilidade e incerteza não são sinônimos. Variabilidade é a diferença que existe entre casos. Incerteza é aquilo que ainda não sabemos. Podemos conhecer muito bem uma distribuição que continua sendo bastante espalhada; ou podemos ter poucos dados muito parecidos e, ainda assim, grande incerteza sobre a população.

Ideia central

A distribuição é uma ponte: ela pega a linguagem “o próximo caso é incerto” e a transforma em uma estrutura matemática verificável.

A.3 Esperança: a média antes de observar o resultado

No Capítulo 2, a média é calculada com valores já observados. Agora suponha que os valores ainda sejam resultados possíveis. A **esperança matemática** é a média de longo prazo da distribuição, ponderada pelas probabilidades.

Para uma variável discreta,

$$E(X) = \sum_x x P(X = x)$$

Exemplo 1 - duas moedas e o número de caras

Defina X = número de caras em dois lançamentos. As sequências possíveis são KK, CK, KC, CC .

Valor x	Caminhos	$P(X = x)$
0	KK	$1/4$
1	CK, KC	$2/4 = 1/2$
2	CC	$1/4$

Então,

$$E(X) = 0 \cdot \frac{1}{4} + 1 \cdot \frac{1}{2} + 2 \cdot \frac{1}{4} = 1.$$

Cuidado com esta confusão

$E(X) = 1$ não significa que todo par de lançamentos produzirá exatamente uma cara. Os resultados continuam sendo 0, 1 ou 2. O valor 1 é o centro de longo prazo da distribuição.

Exemplo 2 - quando a esperança vira decisão

Um procedimento gera economia de R\$20 com probabilidade 0,7 e custo adicional de R\$10 com probabilidade 0,3. Defina G como ganho líquido:

$$G = \begin{cases} 20, & 0,7 \\ -10, & 0,3 \end{cases}$$

$$E(G) = 20(0,7) + (-10)(0,3) = 14 - 3 = 11.$$

Aplicação e decisão no mundo real

Se o procedimento ocorrer milhares de vezes, R\$11 por ocorrência é uma referência para orçamento e comparação com o custo de implantação. Porém, um gestor não deveria decidir apenas pela esperança: precisa saber também quanto os resultados variam. É exatamente por isso que a variância vem logo depois.

Quando posso escrever $E(X) = \mu_X$?

Sempre que μ_X estiver representando a média teórica da distribuição de X :

$$E(X) = \mu_X.$$

Se $X_1, \dots, X_n$ têm a mesma média μ e definimos a média amostral aleatória

$$\bar{X} = \frac{X_1 + \dots + X_n}{n},$$

então

$$E(\bar{X}) = \mu.$$

Isso não significa que uma amostra específica terá $\bar{x} = \mu$. A média observada varia de amostra para amostra. Sob condições usuais, quando n cresce, $\bar{X}$ se aproxima de μ pela Lei dos Grandes Números.

A.4 Variância probabilística: o afastamento esperado em torno da esperança

No Capítulo 2, a variância usa desvios em relação à média observada. No modelo probabilístico, fazemos a mesma pergunta antes de observar o caso:

$$\text{Var}(X) = \text{E} \left[(X - \mu_X)^2 \right].$$

A leitura é literal: **pegue o desvio em relação ao centro, eleve ao quadrado e calcule seu valor esperado.**

Retome X = número de caras em dois lançamentos, com $\mu_X = \text{E}(X) = 1$.

x	$P(X = x)$	$x - \mu$	$(x - \mu)^2$	contribuição
0	1/4	-1	1	$1 \cdot 1/4$
1	1/2	0	0	$0 \cdot 1/2$
2	1/4	1	1	$1 \cdot 1/4$

Somando as contribuições,

$$\text{Var}(X) = \frac{1}{4} + 0 + \frac{1}{4} = \frac{1}{2} = 0,5.$$

De onde vem $\text{Var}(X) = \text{E}(X^2) - [\text{E}(X)]^2$?

Partimos da definição:

$$\text{Var}(X) = \text{E}[(X - \mu)^2].$$

Abra o quadrado:

$$(X - \mu)^2 = X^2 - 2\mu X + \mu^2.$$

Aplique esperança:

$$\text{Var}(X) = \text{E}(X^2) - 2\mu \text{E}(X) + \mu^2.$$

Como $\text{E}(X) = \mu$,

$$\text{Var}(X) = \text{E}(X^2) - 2\mu^2 + \mu^2 = \boxed{\text{E}(X^2) - [\text{E}(X)]^2}.$$

Cuidado com esta confusão

Média dos quadrados e quadrado da média não são a mesma coisa. Neste exemplo,

$$\text{E}(X^2) = 0^2 \frac{1}{4} + 1^2 \frac{1}{2} + 2^2 \frac{1}{4} = 1,5,$$

mas

$$[\text{E}(X)]^2 = 1^2 = 1.$$

A diferença $1,5 - 1 = 0,5$ é a variância.

O desvio-padrão é apenas a raiz da variância:

$$\sigma_X = \sqrt{\text{Var}(X)}.$$


Ele volta para a unidade original da variável.

Aplicação e decisão no mundo real

Duas alternativas podem ter a mesma economia esperada, mas uma oscilar pouco e outra alternar entre ganhos e perdas grandes. A esperança ajuda a comparar centro; a variância e o desvio-padrão ajudam a dimensionar risco, estoque de segurança, caixa ou capacidade extra.

A.5 Antes dos nomes: famílias de distribuições

Agora podemos organizar o vocabulário. **Distribuição** é o conceito geral. Bernoulli, binomial, uniforme e normal são **famílias específicas de distribuição**, cada uma apropriada a um mecanismo diferente.



Ideia central

Não escolha uma distribuição porque a fórmula parece conhecida. Primeiro descreva o mecanismo. A família matemática deve ser uma consequência das condições do problema.

Perguntas de escolha:

- É uma única tentativa com dois resultados? → Bernoulli.
- Quero contar quantos sucessos ocorrem em um número fixo de tentativas independentes com a mesma probabilidade? → Binomial.
- A variável é contínua e todos os subintervalos de mesma largura são modelados com a mesma densidade? → Uniforme.
- A variável é contínua, aproximadamente simétrica, concentrada em torno de um centro e o processo sustenta uma forma de sino? → Normal.

Cuidado com esta confusão

A distribuição normal não é “a próxima versão” da Bernoulli. Elas modelam mecanismos diferentes. A conexão entre distribuições vem das propriedades probabilísticas e, em cursos posteriores, de resultados de aproximação e limites.

A.6 Bernoulli: de uma pergunta binária à fórmula

Comece pela história, não pela fórmula.

Pergunta: o próximo chamado será reaberto?

$$X = \begin{cases} 1, & \text{reaberto,} \\ 0, & \text{não reaberto.} \end{cases}$$

Se $p = P(X = 1)$, necessariamente

$$P(X = 0) = 1 - p.$$

A distribuição completa é simplesmente:

x	significado	probabilidade
0	não ocorre o evento de interesse	$1 - p$
1	ocorre o evento de interesse	p

Só depois comprimimos as duas linhas em uma expressão:

$$P(X = x) = p^x(1 - p)^{1-x}, \quad x \in \{0, 1\}.$$

Por quê funciona?

- se $x = 1$: $p^1(1 - p)^0 = p$;
- se $x = 0$: $p^0(1 - p)^1 = 1 - p$.

A fórmula não acrescenta um novo conceito; ela apenas escreve os dois casos de forma compacta.

Esperança e variância da Bernoulli

$$E(X) = 0(1 - p) + 1(p) = \boxed{p}.$$

Como $X^2 = X$ quando $X \in \{0, 1\}$,

$$\text{Var}(X) = E(X^2) - [E(X)]^2 = p - p^2 = \boxed{p(1 - p)}.$$

Aplicação e decisão no mundo real

Uma empresa define $X = 1$ quando uma transação é contestada e estima $p = 0,03$. Para uma transação isolada, Bernoulli descreve a incerteza 0/1. O valor esperado do indicador é 0,03. Ao transformar isso em volume de milhares de transações, a empresa consegue planejar equipe de análise, reservas e controles. O próximo passo para contar quantos casos ocorrerão é a binomial.

A.7 Binomial: de várias Bernoulli ao número de sucessos

Agora não queremos saber apenas se *um* chamado será reaberto. Queremos saber **quantos** serão reabertos em n chamados.

A binomial exige quatro condições:

1. número fixo de tentativas n ;
2. dois resultados por tentativa;
3. mesma probabilidade de sucesso p em cada tentativa;
4. independência entre as tentativas.

Se X = número de reaberturas em n chamados,

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}.$$

Por que aparecem três pedaços?

Para exatamente k sucessos:

- p^k representa os k sucessos;
- $(1 - p)^{n-k}$ representa os $n - k$ insucessos;
- $\binom{n}{k}$ conta quantas posições diferentes podem conter os k sucessos.

Exemplo do capítulo: 2 reaberturas em 5 chamados

Com $n = 5$, $p = 0,20$ e $k = 2$,


$$\binom{5}{2} = 10,$$

$$P(X = 2) = 10(0,2)^2(0,8)^3 = 0,2048.$$

Logo, a chance modelada é 20,48%.

Para “ao menos uma”, use o complemento:

$$P(X \geq 1) = 1 - P(X = 0) = 1 - (0,8)^5 = 0,67232.$$



Na binomial,

$$E(X) = np, \quad \text{Var}(X) = np(1 - p).$$

Aplicação e decisão no mundo real

Se uma equipe sabe que a chance de pelo menos uma reabertura em cada bloco de cinco chamados é cerca de 67%, pode decidir manter capacidade de retorno no fluxo em vez de planejar como se todos os blocos terminassem sem retrabalho. A decisão depende de custo, SLA e volume, mas a binomial transforma uma taxa individual em risco de volume.

A.8 Distribuições contínuas: densidade e área sem mistério

Em uma variável contínua, existem infinitos valores possíveis dentro de um intervalo. Por isso, a probabilidade não é colocada em “barrinhas” individuais. Ela é distribuída por uma curva de densidade.

Uma densidade válida satisfaz:

$$f_X(x) \geq 0$$

e a área total deve ser 1:

$$\int_{-\infty}^{\infty} f_X(x) dx = 1.$$

A probabilidade de um intervalo é a área dentro dele:

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx.$$

Passo a passo

Para ler um gráfico de densidade:

1. identifique no eixo X o intervalo de interesse;
2. observe a curva $f_X(x)$ no eixo Y ;
3. a probabilidade não é a altura isolada: é a área acumulada sob a curva no intervalo;
4. a soma de todas as áreas possíveis é 100%.

Por que $P(X = x) = 0$ em um modelo contínuo?

Área = largura $\times$ altura, de forma intuitiva. Um ponto isolado possui largura zero. Logo, sua área é zero. Isso não significa que aquele valor não possa aparecer em uma medição arredondada. Significa que o modelo contínuo atribui probabilidade a intervalos, não a pontos individuais.

Consequência:

$$P(X < 10) = P(X \leq 10)$$

para uma variável contínua, pois adicionar ou retirar o ponto 10 acrescenta área zero.

Cuidado com esta confusão

A densidade pode até assumir valores maiores que 1 em algumas distribuições muito concentradas. Isso não viola probabilidade, porque o que precisa ficar entre 0 e 1 é a **área**, não necessariamente a altura da densidade.

A.9 Uniforme: quando a área vira uma simples razão de comprimentos

A uniforme contínua modela densidade constante em um intervalo $[a, b]$:

$$f(x) = \frac{1}{b-a}, \quad a \leq x \leq b.$$

Como a curva é um retângulo, a probabilidade de $c \leq X \leq d$ é:

$$P(c \leq X \leq d) = \frac{d-c}{b-a}.$$

Exemplo do capítulo: chegada entre 0 e 20 minutos

Suponha que um instante seja modelado uniformemente entre 0 e 20 minutos. Então:


$$f(x) = \frac{1}{20} = 0,05.$$

A chance de ocorrer entre 5 e 9 minutos é:

$$P(5 \leq X \leq 9) = (9 - 5) \times 0,05 = 0,20.$$

Ou, de forma equivalente,

$$\frac{9-5}{20-0} = \frac{4}{20} = 20\%.$$



Para a uniforme,

$$E(X) = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{(b-a)^2}{12}.$$

Aplicação e decisão no mundo real

Uma operação sabe que uma tarefa automática começa em um instante aproximadamente uniforme dentro de uma janela de 20 minutos. Se uma manutenção de 4 minutos for agendada dentro dessa janela, o modelo estima 20% de sobreposição. O time pode escolher deslocar a manutenção, reduzir a janela de risco ou aceitar a probabilidade se o impacto for baixo. A uniforme só é defensável se a densidade aproximadamente constante fizer sentido para o processo.

A.10 Normal: primeiro a história, depois a fórmula


A distribuição normal é uma família contínua, simétrica e em forma de sino. Ela é útil quando o processo produz muitos valores próximos de um centro e menos valores muito afastados, e quando essa forma é compatível com os dados e o mecanismo.

Ela possui dois parâmetros:

- μ : determina o centro;
- σ : determina o espalhamento; sua variância é σ^2 .

Escrevemos:

$$X \sim N(\mu, \sigma^2).$$



O que o gráfico mostra? A média é a mesma. Quando σ aumenta, a distribuição fica mais larga e mais baixa, porque a área total continua sendo 1.

Só agora a densidade faz sentido como fórmula:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right].$$

Não é necessário calcular essa exponencial manualmente nesta etapa. A fórmula mostra que a distância $x - \mu$ é comparada com a escala σ .

Regra aproximada 68–95

Em uma normal ideal:

- cerca de 68% da área fica entre $\mu - \sigma$ e $\mu + \sigma$;
- cerca de 95% fica entre $\mu - 2\sigma$ e $\mu + 2\sigma$.

O escore padronizado é

$$z = \frac{x - \mu}{\sigma}.$$

Ele informa quantos desvios-padrão o valor está acima ou abaixo da média.

A.11 Por que $\sigma = 2$ implica variância 4 usando esperança?

Essa pergunta conecta tudo que veio antes.

A definição geral é:

$$\text{Var}(X) = \text{E}[(X - \mu)^2].$$

Uma normal padrão é uma variável

$$Z \sim N(0, 1),$$

com

$$\text{E}(Z) = 0, \quad \text{Var}(Z) = 1.$$

Qualquer normal pode ser escrita como uma transformação:

$$X = \mu + \sigma Z.$$

Logo,

$$X - \mu = \sigma Z.$$

Substituindo na definição da variância:

$$\text{Var}(X) = \text{E}[(\sigma Z)^2] = \text{E}[\sigma^2 Z^2] = \sigma^2 \text{E}(Z^2).$$

Como Z tem média zero e variância 1,

$$\text{E}(Z^2) = 1.$$

Portanto,

$$\text{Var}(X) = \sigma^2.$$

Agora fica transparente:

$$\sigma = 1 \Rightarrow \text{Var}(X) = 1,$$

$$\sigma = 2 \Rightarrow \text{Var}(X) = 4,$$

$$\sigma = 3 \Rightarrow \text{Var}(X) = 9.$$

Ideia central

Dobrar σ dobra a escala dos desvios ($X - \mu$). Como a variância usa **desvios ao quadrado**, dobrar os desvios multiplica a variância por quatro.

Aplicação e decisão no mundo real

Em controle de qualidade, dois processos podem ter a mesma média de diâmetro, mas um possuir $\sigma = 0,1$ mm e outro $\sigma = 0,3$ mm. O segundo é muito mais espalhado e produz mais itens próximos das especificações-limite. A decisão pode ser ajustar o processo mesmo que a média esteja perfeita. Centro correto não garante processo estável.

A.12 Exemplo real integrado: de dados observados à decisão

Uma central mede tempos de atendimento e reaberturas.

Etapla 1 - descrever o passado. Em 100 chamados, 20 foram reabertos. Tempo médio: 12 minutos; desvio-padrão: 3 minutos.

Etapla 2 - transformar uma pergunta em variável aleatória.

$$B = \begin{cases} 1, & \text{reaberto} \\ 0, & \text{não reaberto} \end{cases}$$

Use $p \approx 0,20$ para casos comparáveis. B é Bernoulli.

Etapla 3 - perguntar sobre volume futuro. Em blocos de 5 chamados, seja X = número de reaberturas. Se as condições binomiais forem razoáveis,

$$X \sim \text{Binomial}(5, 0,20).$$

A chance de pelo menos uma é cerca de 67,2%.

Etapla 4 - modelar tempo, se a forma justificar. Se a distribuição dos tempos for aproximadamente simétrica e compatível com uma normal, poderíamos usar

$$T \sim N(12, 3^2).$$

Então 12 é o centro e 3 é a escala de dispersão. Aproximadamente 95% dos tempos do modelo ficariam entre

$$12 - 2(3) = 6 \quad \text{e} \quad 12 + 2(3) = 18 \text{ minutos.}$$

Etapla 5 - decisão. Se o SLA exige conclusão em até 15 minutos, a média 12 sozinha não basta. O desvio-padrão mostra que uma fração relevante pode ultrapassar 15. A equipe precisa medir a proporção real acima do SLA, verificar se a normal é adequada e investigar subgrupos de chamados.

Cuidado com esta confusão

O exemplo é didático: usar uma normal requer olhar a forma dos dados e o mecanismo. Não basta conhecer média e desvio-padrão para declarar normalidade.


Ideia central

A cadeia completa é: **dados observados** $\rightarrow$ **variável aleatória** $\rightarrow$ **distribuição adequada** $\rightarrow$ **esperança e dispersão** $\rightarrow$ **probabilidade de eventos** $\rightarrow$ **decisão**. Nenhuma fórmula precisa aparecer antes da pergunta que a torna necessária.

A.13 Perguntas que surgiram durante o estudo - respostas rápidas

Pergunta	Resposta curta
O que é uma distribuição?	Regra que descreve quais valores X pode assumir e como a probabilidade total é alocada entre eles ou entre regiões.
Discreta e contínua mudam o quê?	Na discreta, valores individuais podem ter massa $P(X = x) > 0$. Na contínua, probabilidade é área sob uma densidade em intervalos.
O que é o eixo Y numa contínua?	Densidade $f_X(x)$, não probabilidade do ponto.
Como calculo a área?	Em geral por integral. Na uniforme, é base $\times$ altura. Na normal, usamos tabelas, software ou regras aproximadas como 68–95.
Por que $P(X = x) = 0$ numa contínua?	Um ponto tem largura zero, então área zero. Não significa impossibilidade física.
Quando $E(X) = \mu_X$?	Quando μ_X denota a média teórica da distribuição de X .
$E(\bar{X}) = \mu$ significa $\bar{x} = \mu$?	Não. O centro da distribuição das médias amostrais é μ , mas uma amostra específica pode produzir outro valor.
O que é $\text{Var}(X)$ pela esperança?	O valor esperado do desvio quadrático: $E[(X - \mu)^2]$.
Por que também vale $E(X^2) - [E(X)]^2$?	É a mesma expressão depois de expandir o quadrado e usar $E(X) = \mu$.
Por que $\sigma = 2$ dá variância 4?	Porque $\sigma = \sqrt{\text{Var}(X)}$, logo $\text{Var}(X) = \sigma^2 = 4$. Pela esperança, os desvios ficam duas vezes maiores e seus quadrados quatro vezes maiores.
Bernoulli é o quê?	Distribuição de uma única tentativa 0/1 com $P(X = 1) = p$.
Binomial é o quê?	Distribuição do número de sucessos em n Bernoulli sob condições específicas.
Normal é o quê?	Distribuição contínua simétrica em sino parametrizada por média μ e desvio-padrão σ .

A.14 Mapa final e ponte para covariância e correlação



Ideia central

O storytelling do capítulo fica completo quando cada objeto nasce de uma necessidade: a média resume centro; a variância resume dispersão; a probabilidade organiza incerteza; a distribuição diz como essa incerteza se espalha; a esperança resume o centro da distribuição; e as famílias Bernoulli, binomial, uniforme e normal são modelos para mecanismos diferentes.

Nota de escopo. O Capítulo 3 original trabalha Bernoulli, binomial, uniforme e normal. Existem muitas outras distribuições (por exemplo, geométrica, Poisson e exponencial), mas elas não são necessárias para fechar a lacuna conceitual deste capítulo e, por isso, não foram introduzidas como conteúdo obrigatório aqui.