

Análise Exploratória de Dados

Capítulo 3 — Da variação à incerteza

Cayo Oliveira

Sumário

3	Da variação à incerteza	3
3.1	Da dispersão observada à incerteza sobre o próximo caso	4
3.2	Experimento aleatório, espaço amostral e evento	5
3.3	União, interseção e probabilidade condicional	7
3.4	Independência, árvores de probabilidade e tabelas	9
3.5	Variável aleatória, esperança e variância probabilística	11
3.6	Bernoulli e binomial	13
3.7	Distribuições uniforme e normal	15
3.8	Covariância: quando duas variáveis se afastam juntas	19
3.9	Correlação de Pearson e a síntese da associação linear	21

Capítulo 3

Da variação à incerteza: probabilidade, distribuições e associação

No capítulo anterior, aprendemos a olhar para valores já observados. Calculamos centros, posições e dispersões para responder como uma turma, um processo ou um conjunto de atendimentos se comportou. Agora surge uma pergunta diferente: o que podemos dizer antes de conhecer o próximo resultado? Um painel informa que 20% dos chamados anteriores foram reabertos; uma equipe quer estimar a chance de a próxima solicitação ser reaberta, a possibilidade de ocorrerem três reaberturas em dez chamados e a relação entre tempo de atendimento e satisfação. A estatística descritiva organiza o passado; a probabilidade cria uma linguagem disciplinada para raciocinar sob incerteza.

Essa linguagem não elimina o acaso e não transforma possibilidade em certeza. Ela especifica o conjunto de resultados possíveis, define quais resultados formam o evento de interesse e atribui números coerentes entre zero e um. Ao longo do capítulo, construiremos experimento aleatório, espaço amostral, evento, complemento, união, interseção, probabilidade condicional e independência. Usaremos tabelas e árvores pequenas para enxergar as relações antes de aplicar fórmulas.

Depois, uma variável aleatória transformará resultados em números e a esperança matemática expressará o valor médio de longo prazo. Distribuições discretas e contínuas organizarão as probabilidades possíveis. Bernoulli e binomial representarão tentativas com dois resultados; a uniforme representará resultados igualmente densos em um intervalo; e a normal introduzirá a conhecida forma de sino sem exigir cálculo integral. Cada modelo virá acompanhado das condições que justificam seu uso.

No fechamento, voltaremos aos dados observados e conectaremos duas variáveis. Covariância mostrará a direção em que elas variam juntas. A correlação de Pearson retirará o efeito das unidades e colocará a associação linear entre -1 e 1 . As contas serão realizadas linha a linha, com tabela de desvios, produtos e quadrados. A advertência de que associação não implica causalidade aparecerá dentro dessa explicação, no ponto em que ela se torna necessária, e não como um bloco desconectado.

O capítulo sustenta um encontro de três horas. Antes da chamada, percorremos a retomada da dispersão, a linguagem de eventos e as regras de combinação. Depois das 20h30, variáveis aleatórias e distribuições preparam a análise conjunta; a última parte calcula covariância e correlação. Não haverá código nem exercícios formais. Os pequenos casos resolvidos pertencem à narrativa do livro e servem para que turma e professor

reconstruam juntos cada decisão matemática.

Síntese da trilha

Então, aluno, veja só a mudança de perspectiva: antes resumimos aquilo que aconteceu; agora formalizaremos aquilo que pode acontecer e, ao final, mediremos como duas características observadas se movem juntas. A ponte entre os dois capítulos é a variação.

3.1 Da dispersão observada à incerteza sobre o próximo caso

Retomemos uma pequena população de tempos, em minutos, 8, 10, 10, 12. Sua média populacional é

$$\mu = \frac{8 + 10 + 10 + 12}{4} = \frac{40}{4} = 10.$$

Os desvios em relação à média são $-2, 0, 0, 2$, e seus quadrados são $4, 0, 0, 4$. A soma quadrática é 8. Como descrevemos toda a população definida, dividimos por $N = 4$:

$$\sigma^2 = \frac{8}{4} = 2 \text{ minutos}^2, \quad \sigma = \sqrt{2} \approx 1,41 \text{ minuto}.$$

A variância e o desvio-padrão descrevem o espalhamento do conjunto que conhecemos. A variância trabalha com desvios ao quadrado; o desvio-padrão retorna à unidade original. Entretanto, nenhum dos dois afirma exatamente qual será o tempo do próximo atendimento. Mesmo em um processo relativamente estável, o próximo caso pode levar oito, dez, doze ou outro número de minutos. A dispersão observada nos avisa que há variação; a probabilidade organiza nossa incerteza sobre resultados ainda não conhecidos.

A necessidade de raciocinar sobre acaso acompanha jogos, seguros, comércio, astronomia e decisões médicas há séculos. Problemas de jogos de azar ajudaram a formalizar a probabilidade nos séculos XVII e XVIII, mas a ideia se tornou muito mais ampla: estimar risco, comparar tratamentos, controlar qualidade e planejar capacidade. O objetivo não é prever individualmente com certeza. É estabelecer regras coerentes para comparar possibilidades e atualizar decisões quando recebemos informação.

Na interpretação clássica, resultados considerados igualmente possíveis permitem calcular probabilidade como razão entre casos favoráveis e casos possíveis. Em um dado honesto, a chance de obter um número par é $3/6 = 1/2$. Essa abordagem funciona quando a simetria justifica a igualdade. Na interpretação frequentista, a probabilidade descreve a frequência relativa que tende a se estabilizar em muitas repetições. Na interpretação subjetiva ou bayesiana, representa um grau de crença coerente diante da informação disponível. Neste capítulo, usaremos principalmente contagem e frequência, sempre declarando as condições.

Uma probabilidade $P(A)$ precisa satisfazer $0 \leq P(A) \leq 1$. Zero representa evento impossível no modelo; um, evento certo. Se todos os resultados possíveis formam o espaço Ω , então $P(\Omega) = 1$. Eventos mutuamente exclusivos podem ter probabilidades somadas. Esses princípios parecem simples, mas evitam contradições como atribuir 70% de chance a um evento e 50% a seu complemento.

O número não é mais forte do que o modelo. Dizer que há 20% de chance de reabertura pode significar que vinte em cem casos comparáveis foram reabertos, mas o valor deixa

de servir se mudarem produto, equipe, período ou definição de reabertura. Probabilidade não apaga contexto. Ela condiciona uma afirmação a um experimento e a premissas que precisam ser sustentadas.

Começaremos, portanto, não por uma fórmula, mas por três objetos: qual processo pode produzir um resultado, quais resultados consideramos possíveis e qual conjunto deles interessa à decisão. Esses objetos recebem os nomes experimento, espaço amostral e evento.

Há ainda uma distinção prática entre variabilidade e incerteza. Variabilidade é a diferença efetiva entre unidades ou repetições: alguns atendimentos duram mais do que outros. Incerteza é aquilo que não sabemos sobre um caso, uma média ou um mecanismo. Podemos ter grande variabilidade e pouca incerteza sobre a distribuição quando possuímos muitos dados estáveis; também podemos ter valores próximos entre si e grande incerteza porque observamos apenas duas unidades. A probabilidade será usada para representar mecanismos e incertezas declaradas, sem confundir a diferença que existe no mundo com a falta de informação de quem analisa.

Síntese da trilha

Então, aluno, veja só o que você retomou: variância e desvio-padrão descrevem dispersão já observada. A probabilidade começa quando usamos um modelo para falar de resultados ainda incertos. O valor numérico só faz sentido junto das condições que definem o processo.

3.2 Experimento aleatório, espaço amostral e evento

Um **experimento aleatório** é um procedimento cujo resultado não é conhecido antes da realização, embora o conjunto de possibilidades possa ser descrito. Lançar uma moeda, observar se um chamado será reaberto, medir o tempo da próxima consulta e selecionar uma matrícula são experimentos em sentidos diferentes. A palavra “experimento” não exige laboratório; exige uma regra que diga o que será realizado e qual observação encerrará a tentativa.

O **espaço amostral**, indicado por Ω , reúne todos os resultados elementares considerados possíveis. Em um lançamento de dado,

$$\Omega = \{1, 2, 3, 4, 5, 6\}.$$

Em um chamado classificado apenas como reaberto ou não reaberto,

$$\Omega = \{R, N\}.$$

Se medimos tempo, o espaço pode ser contínuo, como todos os valores reais não negativos. A qualidade do espaço depende do nível de detalhe da pergunta.

Um **evento** é um subconjunto de Ω . No dado, o evento $A = \text{“resultado par”}$ é $A = \{2, 4, 6\}$. O evento $B = \text{“resultado maior que quatro”}$ é $B = \{5, 6\}$. Cada resultado isolado também pode formar um evento, como $\{3\}$. O evento impossível é o conjunto vazio, $\emptyset$, e o evento certo é o próprio espaço amostral.

Quando os seis resultados do dado são igualmente prováveis, usamos

$$P(A) = \frac{|A|}{|\Omega|}.$$

$|A|$ é a quantidade de elementos favoráveis e $|\Omega|$ a quantidade total. Para $A = \{2, 4, 6\}$,

$$P(A) = \frac{3}{6} = \frac{1}{2} = 0,5 = 50\%.$$

Para $B = \{5, 6\}$,

$$P(B) = \frac{2}{6} = \frac{1}{3} \approx 0,333 = 33,3\%.$$

Essa razão não deve ser aplicada mecanicamente. Em uma moeda deformada, cara e coroa podem não ter a mesma probabilidade. Em dados de atendimento, reaberto e não reaberto são duas categorias, mas não recebem automaticamente $1/2$ cada. Podemos estimar a chance pela frequência histórica: se 18 de 120 chamados comparáveis foram reabertos,

$$\hat{P}(R) = \frac{18}{120} = 0,15 = 15\%.$$

O chapéu indica estimativa obtida da amostra, não uma verdade exata e eterna.

O **complemento** de A , escrito A^c , reúne tudo que está em Ω e não pertence a A . Como A e A^c esgotam as possibilidades e não se sobrepõem,

$$P(A^c) = 1 - P(A).$$

Se $P(R) = 0,15$, então

$$P(R^c) = 1 - 0,15 = 0,85 = 85\%.$$

Interpretamos: no modelo e na população de referência, a chance de um chamado não ser reaberto é 85%.

O complemento é especialmente útil para eventos como “ao menos um”. Muitas vezes é mais simples calcular a chance de nenhum caso e subtrair de um. Essa estratégia aparecerá na binomial. Antes, precisamos aprender a combinar eventos por união e interseção, distinguindo “ou” de “e”.

Também é necessário distinguir resultado elementar de evento composto. No dado, o resultado 4 é elementar porque corresponde a um único elemento de Ω ; “par” é composto porque reúne três resultados. Em um sistema, porém, o que parece elementar depende da representação: “reaberto” pode ocultar reabertura por falha técnica, informação incompleta ou mudança do cliente. Refinar o espaço amostral permite perguntas melhores, mas exige dados mais detalhados. Simplificá-lo facilita a conta, porém pode esconder diferenças decisivas. Assim, definir Ω já é uma escolha analítica.

Explicação guiada

Aluno, preste atenção aqui: duas categorias não significam duas chances iguais. A contagem de casos favoráveis sobre casos possíveis só vale diretamente quando os resultados elementares são equiprováveis. Em dados reais, a probabilidade precisa ser estimada ou sustentada por outro modelo.

Síntese da trilha

Então, aluno, veja só o que você aprendeu aqui: experimento define o procedimento; espaço amostral reúne os resultados possíveis; evento seleciona os resultados relevantes. O complemento contém tudo que não pertence ao evento e possui probabilidade $1 - P(A)$.

3.3 União, interseção e probabilidade condicional

Decisões reais combinam condições. Uma coordenação pode perguntar pela chance de um estudante ter baixa frequência *ou* nota pendente; uma equipe pode investigar chamados urgentes *e* reabertos. A **união** $A \cup B$ representa “A ou B ou ambos”. A **interseção** $A \cap B$ representa “A e B simultaneamente”. As palavras cotidianas podem ser ambíguas; os conjuntos tornam a relação explícita.

Para quaisquer eventos,

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Subtraímos a interseção porque ela foi contada uma vez em $P(A)$ e outra em $P(B)$. No dado, $A = \text{par} = \{2, 4, 6\}$ e $B = \text{maior que quatro} = \{5, 6\}$. A interseção é $A \cap B = \{6\}$; a união é $A \cup B = \{2, 4, 5, 6\}$. Assim,

$$P(A \cup B) = \frac{3}{6} + \frac{2}{6} - \frac{1}{6} = \frac{4}{6} = \frac{2}{3}.$$

Se os eventos são mutuamente exclusivos, sua interseção é vazia. Em um único lançamento, “obter 1” e “obter 6” não podem ocorrer juntos, então $P(A \cap B) = 0$ e a união é apenas a soma. Entretanto, “par” e “maior que quatro” não são exclusivos porque compartilham o 6. Somar $3/6 + 2/6 = 5/6$ seria contar o resultado 6 duas vezes.

A **probabilidade condicional** responde como a chance de A muda quando sabemos que B ocorreu:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0.$$

O símbolo $|$ é lido “dado que”. O denominador $P(B)$ mostra que restringimos o universo aos casos em B . Dentro desse novo universo, contamos quais também pertencem a A .

Considere uma turma de 40 estudantes. Vinte e quatro trabalham durante o dia (T); dezesseis não trabalham. Doze dos que trabalham chegaram atrasados (A), e quatro dos que não trabalham chegaram atrasados. A tabela organiza as contagens:

	Atrasou A	Não atrasou A^c	Total
Trabalha T	12	12	24
Não trabalha T^c	4	12	16
Total	16	24	40

Sem condição, $P(A) = 16/40 = 0,40$. Sabendo que o estudante trabalha, restringimos aos 24 trabalhadores; entre eles, 12 atrasaram:

$$P(A | T) = \frac{12}{24} = 0,50.$$

Sabendo que não trabalha,

$$P(A | T^c) = \frac{4}{16} = 0,25.$$

O resultado não afirma que trabalhar causa atraso; apenas descreve como a proporção observada muda entre os grupos.

Podemos reorganizar a fórmula condicional para obter a regra do produto:

$$P(A \cap B) = P(A | B)P(B).$$

No exemplo,

$$P(A \cap T) = P(A | T)P(T) = \frac{12}{24} \times \frac{24}{40} = \frac{12}{40} = 0,30.$$

A conta acompanha uma sequência: selecionar um trabalhador e, dentro desse grupo, observar atraso.

A probabilidade condicional prepara a ideia de independência. Se conhecer B não alterar a chance de A , os eventos são independentes. Se alterar, existe dependência probabilística no modelo. Precisamos distinguir essa definição de exclusão mútua, porque eventos impossíveis de ocorrer juntos quase nunca são independentes.

O sentido da condição também importa: $P(A | T)$ geralmente não é igual a $P(T | A)$. No exemplo, $P(A | T) = 12/24 = 0,50$, enquanto $P(T | A) = 12/16 = 0,75$. A primeira pergunta seleciona trabalhadores e procura atrasos; a segunda seleciona atrasados e procura trabalhadores. Numerador e denominador mudam porque o universo de referência mudou. Confundir as direções é comum em notícias sobre exames, riscos e classificadores. Antes de dividir, diga em voz alta qual grupo já é conhecido e qual característica será procurada dentro dele.

Vejamos um segundo exemplo resolvido, agora com um teste de triagem. Em mil atendimentos, cem pacientes possuem a condição investigada. O teste sinaliza positivo para noventa desses cem e também para noventa dos novecentos sem a condição. Assim, existem 180 resultados positivos, dos quais apenas 90 correspondem a pacientes com a condição. A sensibilidade é $P(+ | D) = 90/100 = 90\%$, mas a pergunta feita por quem recebeu o resultado é inversa: $P(D | +) = 90/180 = 50\%$. O mesmo número 90 aparece nos dois cálculos, porém os denominadores são diferentes porque as perguntas selecionam universos diferentes.

Esse caso funciona como contraexemplo para a intuição de que “um teste com noventa por cento” implica noventa por cento de chance após um positivo. A taxa básica da condição participa da interpretação. Se a condição fosse mais rara, os falsos positivos poderiam representar parcela ainda maior dos sinais; se fosse mais comum, a parcela de positivos verdadeiros aumentaria, mantendo as mesmas características do teste. Probabilidade condicional não é uma etiqueta permanente do evento: é uma relação entre evento, condição e população de referência.

Outro contraexemplo aparece quando trocamos “ou” por uma soma automática. Se 60% dos estudantes usam transporte público e 50% trabalham, não podemos concluir que 110% usam transporte ou trabalham. Precisamos conhecer a interseção. Se 35% fazem as duas coisas, então $P(T \cup W) = 0,60 + 0,50 - 0,35 = 0,75$. Os 35% foram contados nas duas parcelas e precisam ser retirados uma vez. O resultado final, 75%, responde à união inclusiva: transporte, trabalho ou ambos.

Síntese da trilha

Então, aluno, veja só o que você aprendeu aqui: união é “A ou B”, interseção é “A e B”. Na união, retiramos a interseção contada duas vezes. Na condicional, reduzimos o universo aos casos em B e observamos que parcela também está em A .

3.4 Independência, árvores de probabilidade e tabelas

Dois eventos A e B são **independentes** quando saber que um ocorreu não altera a probabilidade do outro. Formalmente,

$$P(A | B) = P(A),$$

desde que $P(B) > 0$. Uma forma equivalente é

$$P(A \cap B) = P(A)P(B).$$

A independência é uma propriedade a ser justificada pelo desenho do processo ou verificada no modelo; não deve ser presumida apenas para simplificar a conta.

Considere dois lançamentos de uma moeda honesta. O resultado do primeiro lançamento não altera o mecanismo do segundo. Se C_1 é cara no primeiro e C_2 é cara no segundo, $P(C_1) = 1/2$ e $P(C_2) = 1/2$. Pela independência,

$$P(C_1 \cap C_2) = \frac{1}{2} \times \frac{1}{2} = \frac{1}{4}.$$

O espaço com sequências CC, CK, KC, KK confirma quatro resultados equiprováveis, um deles com duas caras.

Eventos mutuamente exclusivos são diferentes. No mesmo lançamento, $A = \text{cara}$ e $B = \text{coroa}$ possuem $P(A \cap B) = 0$, mas $P(A)P(B) = 1/4$. Como $0 \neq 1/4$, não são independentes. Saber que saiu cara muda a chance de coroa para zero. Exclusão mútua significa que não ocorrem juntos; independência significa que a ocorrência de um não informa sobre o outro.

Uma árvore de probabilidade torna sequências visíveis. Suponha que 20% dos chamados sejam urgentes (U). Entre urgentes, 30% são reabertos (R); entre não urgentes, 10% são reabertos. O primeiro nível possui $P(U) = 0,20$ e $P(U^c) = 0,80$. Do ramo U saem $P(R | U) = 0,30$ e $P(R^c | U) = 0,70$. Do ramo U^c saem $P(R | U^c) = 0,10$ e $P(R^c | U^c) = 0,90$.

A Figura 3.1 desenha exatamente esses dois estágios. Leia primeiro da esquerda para a direita: a primeira bifurcação separa urgência; a segunda usa probabilidades condicionais de reabertura dentro de cada ramo. Os valores nas folhas são probabilidades conjuntas, obtidas pela multiplicação ao longo do caminho.

Na Figura 3.1, as duas folhas de reabertura somam $0,06 + 0,08 = 0,14$. Observe também que os ramos saindo de cada nó somam um: $0,30 + 0,70 = 1$ entre urgentes e $0,10 + 0,90 = 1$ entre não urgentes. Essa verificação simples encontra muitos erros de árvore. Não somamos $0,30$ com $0,10$ diretamente, pois são probabilidades definidas em grupos de tamanhos diferentes; primeiro ponderamos pelo tamanho probabilístico de cada ramo.

Multiplicamos ao longo de cada caminho. Para urgente e reaberto,

$$P(U \cap R) = 0,20 \times 0,30 = 0,06.$$

Para não urgente e reaberto,

$$P(U^c \cap R) = 0,80 \times 0,10 = 0,08.$$




Figura 3.1: Árvore de urgência e reabertura: multiplicar ao longo de um caminho e somar caminhos que chegam ao mesmo evento.

Somamos caminhos alternativos que chegam a reabertura:

$$P(R) = 0,06 + 0,08 = 0,14.$$

Portanto, a chance total de reabertura é 14%.

A mesma informação cabe em uma tabela de probabilidades conjuntas:

	R	R^c	Total
U	0,06	0,14	0,20
U^c	0,08	0,72	0,80
Total	0,14	0,86	1,00

Urgência e reabertura não são independentes, pois $P(R | U) = 0,30$, enquanto $P(R) = 0,14$. Conhecer urgência muda a chance estimada. Também podemos verificar pelo produto: $P(U)P(R) = 0,20 \times 0,14 = 0,028$, diferente de $P(U \cap R) = 0,06$. Isso mede dependência probabilística, mas ainda não explica o mecanismo. Chamados urgentes podem envolver problemas mais complexos, clientes diferentes ou critérios de registro distintos.

Explicação guiada

Aluno, preste atenção aqui: em árvore, multiplique ao seguir um caminho e some caminhos alternativos que formam o mesmo evento. A árvore mostra condicionais; a tabela mostra cruzamentos. As duas representações devem levar ao mesmo total.

As árvores descrevem resultados categóricos. Para calcular médias esperadas de ganhos, custos, contagens ou tempos, precisamos atribuir um número a cada resultado. Essa função recebe o nome variável aleatória.

Em aplicações, independência pode ser razoável apenas condicionalmente. Resultados de estudantes da mesma turma compartilham professor e avaliação; chamados do mesmo cliente compartilham infraestrutura; medições sucessivas de uma máquina compartilham desgaste. Tratar essas unidades como tentativas independentes faz a quantidade de informação parecer maior do que realmente é. Uma árvore pequena ajuda a perguntar onde

existe memória ou agrupamento. Quando a premissa não se sustenta, não “consertamos” a realidade para caber no produto das probabilidades; buscamos um modelo que represente a dependência.

Um exemplo numérico ajuda a testar a definição. Em um baralho comum, seja A = “carta vermelha” e B = “carta de figura”. Temos $P(A) = 26/52 = 1/2$, $P(B) = 12/52 = 3/13$ e seis figuras vermelhas, portanto $P(A \cap B) = 6/52 = 3/26$. O produto é $(1/2)(3/13) = 3/26$, exatamente igual à interseção. Nesse modelo de uma carta, cor e condição de figura são independentes. Saber que a carta é vermelha não altera a proporção de figuras: continuam seis entre vinte e seis, ou $3/13$.

Agora mude o procedimento: retiramos duas cartas sem reposição e definimos A = “a primeira é ás” e B = “a segunda é ás”. A chance inicial da segunda ser ás é $4/52$, por simetria. Contudo, se sabemos que a primeira foi ás, restam apenas três ases entre cinquenta e uma cartas, de modo que $P(B | A) = 3/51$. Como $3/51 \neq 4/52$, os eventos não são independentes. A retirada sem reposição criou memória no processo. O contraexemplo mostra por que repetir uma fórmula de produto sem descrever reposição pode produzir uma resposta numericamente organizada e conceitualmente errada.

Síntese da trilha

Então, aluno, veja só o que você aprendeu aqui: independência significa que a informação sobre um evento não muda a chance do outro. Em sequências, multiplicamos probabilidades condicionais ao longo de ramos e somamos caminhos que compõem o evento desejado.

3.5 Variável aleatória, esperança e variância probabilística

Uma **variável aleatória** é uma função que associa um número real a cada resultado do experimento. O nome pode sugerir que a variável muda sem regra, mas a função é fixa; o acaso está em qual resultado ocorrerá. Em dois lançamentos de moeda, podemos definir X = número de caras. As sequências KK, CK, KC, CC recebem respectivamente os valores 0, 1, 1, 2. Assim, transformamos resultados em uma quantidade analisável.

Uma variável aleatória é **discreta** quando assume valores contáveis, como 0, 1, 2 caras ou número de reaberturas. É **contínua** quando pode assumir qualquer valor em intervalos, como tempo e temperatura idealizados. A distinção muda a forma de atribuir probabilidade: na discreta, somamos massas em valores; na contínua, calculamos áreas em intervalos e a probabilidade de um ponto exato é zero no modelo.

A distribuição de probabilidade de X informa a chance de cada valor. Para duas moedas honestas independentes,

$$P(X = 0) = \frac{1}{4}, \quad P(X = 1) = \frac{2}{4} = \frac{1}{2}, \quad P(X = 2) = \frac{1}{4}.$$

As probabilidades são não negativas e somam um:

$$\frac{1}{4} + \frac{1}{2} + \frac{1}{4} = 1.$$

O valor 1 possui maior probabilidade porque pode surgir por dois caminhos, CK e KC .

A **esperança matemática** ou valor esperado é a média ponderada dos valores possíveis por suas probabilidades:

$$E(X) = \sum_x xP(X = x).$$

x percorre os valores possíveis e $P(X = x)$ funciona como peso. Para o número de caras,

$$E(X) = 0 \times \frac{1}{4} + 1 \times \frac{1}{2} + 2 \times \frac{1}{4} = 0 + \frac{1}{2} + \frac{1}{2} = 1.$$

Em muitas repetições de dois lançamentos, esperamos em média uma cara por par de lançamentos. Isso não significa que cada experimento produzirá uma cara.

O valor esperado atende à necessidade de planejar sob repetição. Considere um procedimento que economiza R\$ 20 com probabilidade 0,7 e gera custo adicional de R\$ 10 com probabilidade 0,3. Defina $G = 20$ no primeiro caso e $G = -10$ no segundo. Então,

$$E(G) = 20 \times 0,7 + (-10) \times 0,3 = 14 - 3 = 11.$$

O ganho esperado é R\$ 11 por ocorrência no modelo. Nenhuma ocorrência individual produz R\$ 11; os resultados possíveis continuam sendo R\$ 20 e R\$ -10.

Uma distribuição também possui variância:

$$\text{Var}(X) = E[(X - \mu_X)^2] = \sum_x (x - \mu_X)^2 P(X = x),$$

em que $\mu_X = E(X)$. Para o número de caras, $\mu_X = 1$. Calculamos

$$\text{Var}(X) = (0 - 1)^2 \frac{1}{4} + (1 - 1)^2 \frac{1}{2} + (2 - 1)^2 \frac{1}{4} = \frac{1}{4} + 0 + \frac{1}{4} = \frac{1}{2}.$$

O desvio-padrão é $\sqrt{1/2} \approx 0,707$ cara por experimento de dois lançamentos.

Esperança não basta para decidir entre alternativas com riscos distintos. Duas estratégias podem ter o mesmo ganho esperado e dispersões muito diferentes. Uma oferece ganho quase constante; outra alterna grande ganho e grande perda. A variância probabilística complementa a esperança assim como a variância descritiva complementou a média observada. A diferença é que agora ponderamos resultados possíveis pelas probabilidades do modelo.

Essa estrutura abre o caminho para distribuições nomeadas. Em vez de listar manualmente todas as probabilidades a cada problema, reconhecemos um mecanismo e usamos uma família matemática cujos parâmetros resumem as condições.

Uma transformação simples mostra por que a esperança é útil. Se cada reabertura custa R\$ 30, e X conta reaberturas, então o custo é $C = 30X$. Pela linearidade, $E(C) = 30E(X)$. Se esperamos uma reabertura por lote, esperamos R\$ 30 de custo por lote, embora os custos reais possam ser R\$ 0, R\$ 30, R\$ 60 ou mais. A palavra “esperado” descreve média de longo prazo sob o modelo. Para orçamento, precisamos ainda da dispersão e de quantis, pois financiar apenas o valor médio pode ser insuficiente nos lotes desfavoráveis.

Síntese da trilha

Então, aluno, veja só o que você aprendeu aqui: variável aleatória traduz resultados em números. Esperança é a média ponderada pelas probabilidades; variância probabilística mede o afastamento quadrático esperado. Nenhuma das duas promete o resultado de uma tentativa isolada.

3.6 Bernoulli e binomial: modelando tentativas com dois resultados

A distribuição de **Bernoulli** representa uma única tentativa com dois resultados codificados como sucesso 1 e insucesso 0. “Sucesso” é apenas o evento de interesse, não um julgamento positivo. Em qualidade, sucesso pode significar defeito detectado; em atendimento, reabertura; em educação, entrega no prazo. O parâmetro p é a probabilidade de $X = 1$, e $1 - p$ é a probabilidade de $X = 0$.

Sua função de probabilidade pode ser escrita

$$P(X = x) = p^x(1 - p)^{1-x}, \quad x \in \{0, 1\}.$$

Se $x = 1$, obtemos $p^1(1 - p)^0 = p$. Se $x = 0$, obtemos $p^0(1 - p)^1 = 1 - p$. A fórmula reúne os dois casos. Para Bernoulli,

$$E(X) = p, \quad \text{Var}(X) = p(1 - p).$$

Se a chance de reabertura é 0,2, o indicador médio é 0,2 e a variância é $0,2 \times 0,8 = 0,16$.

A distribuição **binomial** conta sucessos em n tentativas Bernoulli. Ela exige um número fixo de tentativas, dois resultados por tentativa, probabilidade p constante e independência entre tentativas. Se essas condições não forem razoáveis, a fórmula pode produzir um número preciso para um modelo inadequado. Por exemplo, chamados do mesmo cliente podem ser dependentes, e a taxa de reabertura pode mudar entre equipes.

Se X é o número de sucessos, sua probabilidade é

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k},$$

para $k = 0, 1, \dots, n$. O coeficiente

$$\binom{n}{k} = \frac{n!}{k!(n - k)!}$$

conta quantas sequências diferentes possuem exatamente k sucessos. O termo p^k representa os sucessos; $(1 - p)^{n-k}$, os insucessos.

Calculemos a chance de exatamente duas reaberturas em cinco chamados, assumindo independência e $p = 0,2$. Primeiro, o número de maneiras de escolher duas posições entre cinco:

$$\binom{5}{2} = \frac{5!}{2!3!} = \frac{5 \times 4 \times 3!}{(2 \times 1)3!} = \frac{20}{2} = 10.$$

Depois,

$$p^2 = 0,2^2 = 0,04, \quad (1 - p)^3 = 0,8^3 = 0,512.$$

Multiplicamos:

$$P(X = 2) = 10 \times 0,04 \times 0,512 = 0,2048.$$

A chance modelada é 20,48%.

Para “ao menos uma reabertura”, o complemento evita somar quatro casos. Calculamos nenhuma e subtraímos de um:

$$P(X \geq 1) = 1 - P(X = 0).$$

Como $\binom{5}{0} = 1$,

$$P(X = 0) = 1 \times 0,2^0 \times 0,8^5 = 0,32768.$$

Logo,

$$P(X \geq 1) = 1 - 0,32768 = 0,67232 = 67,232\%.$$

Uma chance individual de 20% acumula-se em cinco oportunidades.

A Figura 3.2 apresenta toda a distribuição desse mesmo caso. Cada haste representa $P(X = k)$ para $k = 0, 1, \dots, 5$. A figura permite comparar onde a massa se concentra e enxergar por que esperança igual a um não significa certeza de uma reabertura.




Figura 3.2: Distribuição binomial para $n = 5$ e $p = 0,20$. A maior massa está em uma reabertura, mas outros totais continuam possíveis.

Na Figura 3.2, $P(X = 1) = 5(0,2)(0,8)^4 = 0,4096$ é a haste mais alta. A probabilidade de zero, 0,32768, ainda é considerável; exatamente duas possui 0,2048; três ou mais concentram pouca massa. Somando todas as hastes obtemos um. Somando as hastes de um a cinco obtemos novamente 0,67232, a probabilidade de ao menos uma calculada pelo complemento. A representação visual e a conta precisam concordar.

Considere agora outro exemplo resolvido: em oito entregas, a chance modelada de atraso é $p = 0,10$. A probabilidade de exatamente dois atrasos é

$$P(X = 2) = \binom{8}{2}(0,10)^2(0,90)^6 = 28 \times 0,01 \times 0,531441 \approx 0,1488.$$

Portanto, sob as quatro premissas binomiais, cerca de 14,88% dos lotes de oito teriam exatamente dois atrasos em repetição de longo prazo. O coeficiente 28 não aumenta a chance arbitrariamente: ele conta as vinte e oito posições possíveis para os dois atrasos.

Como contraexemplo, imagine oito entregas realizadas pela mesma motocicleta durante uma tempestade que piora ao longo da noite. A chance de atraso não permanece constante, e um atraso inicial pode afetar os horários seguintes. Embora cada entrega possa ser rotulada atraso/não atraso e o total varie de zero a oito, a binomial deixa de representar adequadamente o mecanismo. Ter uma contagem inteira e dois rótulos é necessário, mas não suficiente. A pergunta correta deixa de ser “qual número coloco em p ?” e passa a ser “como represento dependência e mudança ao longo do tempo?”.

Na binomial,

$$E(X) = np, \quad \text{Var}(X) = np(1 - p).$$

Para $n = 5$ e $p = 0,2$, $E(X) = 5 \times 0,2 = 1$ reabertura e $\text{Var}(X) = 5 \times 0,2 \times 0,8 = 0,8$. O desvio-padrão é $\sqrt{0,8} \approx 0,894$. Novamente, a esperança 1 não afirma que cada lote terá exatamente uma reabertura.

Explicação guiada

Aluno, preste atenção aqui: binomial não significa apenas “contar sim e não”. Verifique número fixo de tentativas, dois resultados, p constante e independência. A fórmula deve ser consequência do mecanismo, não um molde escolhido porque os dados são inteiros.

Bernoulli e binomial são discretas: atribuem massa a valores contáveis. Tempos e medidas pedem modelos contínuos. Começaremos por uma densidade constante, a uniforme, e depois veremos a forma de sino da normal.

O parâmetro p merece atenção porque raramente é conhecido com exatidão. Se foi estimado por 20 reaberturas em 100 chamados, usamos $\hat{p} = 0,20$ como aproximação. Outro período poderia gerar 18% ou 23%. A probabilidade binomial calculada herda essa incerteza, além das premissas de constância e independência. Apresentar 20,48% com muitas casas não torna a evidência mais precisa. A conta exata dentro do modelo e a adequação do modelo são perguntas diferentes, e ambas precisam aparecer na interpretação.

Síntese da trilha

Então, aluno, veja só o que você aprendeu aqui: Bernoulli descreve uma tentativa com indicador 0/1; binomial conta sucessos em n tentativas sob condições explícitas. O coeficiente combinatório conta as posições possíveis dos sucessos.

3.7 Distribuições contínuas: uniforme e normal em linguagem introdutória

Em uma variável contínua, probabilidades pertencem a intervalos. Uma densidade $f(x)$ deve ser não negativa e possuir área total igual a um. A probabilidade de $a \leq X \leq b$ é a área sob a curva entre a e b . Como um ponto isolado tem largura zero, $P(X = x) = 0$ no modelo contínuo, mesmo que valores arredondados apareçam repetidos em uma planilha.

Antes da curva teórica, precisamos olhar a forma observada. Um histograma divide uma variável quantitativa em intervalos, chamados classes ou *bins*, e mostra em cada intervalo a contagem ou a frequência relativa. Diferentemente de um gráfico de barras categórico, as barras do histograma representam trechos contíguos do eixo numérico: a

vizinhança entre 10–15 e 15–20 possui significado. A escolha das fronteiras e larguras resume os dados; não é uma fotografia “exata” e neutra da distribuição.

Considere tempos em minutos 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 20, 21. Com classes $[0, 5)$, $[5, 10)$, $[10, 15)$, $[15, 20)$ e $[20, 25)$, as frequências são respectivamente 1, 5, 4, 0, 2. A lacuna entre quinze e vinte e o pequeno grupo final ficam visíveis. Se usarmos apenas duas classes, $[0, 12,5)$ e $[12,5, 25)$, obtemos 9 e 3 e escondemos a lacuna. Se criarmos uma classe para cada minuto, a figura fica serrilhada e o padrão geral perde legibilidade. Poucos bins podem esconder estrutura; bins demais podem transformar variação amostral em ruído visual.

A Figura 3.3 mostra as duas primeiras escolhas para os mesmos dados. Observe que nenhum valor mudou. Mudou apenas a discretização usada para resumir a forma. A leitura responsável informa limites das classes, contagem ou densidade no eixo vertical e tamanho da amostra.




Figura 3.3: Os mesmos tempos em histogramas com bins diferentes. A discretização altera o padrão visível, não os dados originais.

Na Figura 3.3, a escolha de cinco minutos revela cauda e lacuna; a escolha grosseira resume apenas concentração geral. Uma heurística como $k \approx 1 + 3,3 \log_{10}(n)$ pode sugerir um ponto inicial para a quantidade de classes, mas não escolhe automaticamente a melhor representação. Precisamos comparar alternativas, manter escalas honestas e perguntar que estrutura permanece estável. Uma forma aproximadamente simétrica sem extremos costuma ser bem resumida por média e desvio-padrão; assimetria ou extremos pedem também mediana e IQR; duas modas convidam a investigar subgrupos.

A distribuição **uniforme contínua** representa densidade constante no intervalo $[a, b]$. Sua função é

$$f(x) = \frac{1}{b-a}, \quad a \leq x \leq b,$$

e zero fora. O denominador $b - a$ é a largura total; multiplicar altura $1/(b - a)$ pela largura produz área um. A probabilidade de um subintervalo é sua largura dividida pela largura total.

Suponha que um instante de chegada seja modelado uniformemente entre 0 e 20 minutos. Então $a = 0$, $b = 20$ e $f(x) = 1/20 = 0,05$. A chance de chegar entre 5 e 9 minutos

é

$$P(5 \leq X \leq 9) = \frac{9 - 5}{20 - 0} = \frac{4}{20} = 0,20.$$

O resultado de 20% vem da faixa de quatro minutos dentro de uma janela de vinte. Essa uniformidade precisa ser justificável; horários reais frequentemente concentram chegadas.

Para a uniforme,

$$E(X) = \frac{a + b}{2}, \quad \text{Var}(X) = \frac{(b - a)^2}{12}.$$

No intervalo $[0, 20]$, a esperança é $(0 + 20)/2 = 10$ minutos. A variância é $20^2/12 = 400/12 \approx 33,33$ minutos², e o desvio-padrão é $\sqrt{33,33} \approx 5,77$ minutos. A simetria coloca o centro exatamente no ponto médio.

A distribuição **normal** surgiu no estudo de erros de medição e foi conectada aos trabalhos de De Moivre, Laplace e Gauss. Sua forma simétrica de sino tornou-se central porque muitos efeitos pequenos e aproximadamente independentes podem produzir somas próximas da normal. A normal é definida por média μ e desvio-padrão σ . A média determina o centro; o desvio-padrão determina a abertura.

Sua densidade é

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right].$$

Não precisamos calcular exponenciais manualmente nesta introdução. Precisamos ler os símbolos: $x - \mu$ é a distância ao centro; o quadrado torna a curva simétrica; σ^2 controla como essa distância é escalada; e o fator frontal garante área total um. Aproximadamente 68% da área fica entre $\mu - \sigma$ e $\mu + \sigma$, 95% entre $\mu - 2\sigma$ e $\mu + 2\sigma$, em uma normal ideal.

O escore padronizado

$$z = \frac{x - \mu}{\sigma}$$

informa quantos desvios-padrão um valor está acima ou abaixo da média. Se tempos forem aproximadamente normais com $\mu = 50$ e $\sigma = 5$, um tempo $x = 60$ tem

$$z = \frac{60 - 50}{5} = \frac{10}{5} = 2.$$

Ele está dois desvios-padrão acima da média. Um tempo 45 tem $z = (45 - 50)/5 = -1$, um desvio abaixo.

A Figura 3.4 separa os papéis de média e desvio-padrão. No painel esquerdo, as curvas possuem o mesmo σ e centros diferentes; no direito, possuem a mesma média, mas dispersões diferentes. Antes de olhar os eixos, antecipe: mudar μ desloca o sino; aumentar σ espalha a mesma área total e reduz a altura do pico.

No painel esquerdo da Figura 3.4, os dois processos possuem a mesma variabilidade modelada, mas níveis típicos diferentes. No painel direito, os centros coincidem, porém a curva com $\sigma = 9$ atribui mais densidade às regiões afastadas. Ela fica mais baixa porque a área total continua sendo um. Uma curva mais alta não representa “mais casos” quando comparamos densidades normalizadas; representa maior concentração por unidade do eixo horizontal.

Para completar a leitura de z , suponha notas aproximadamente normais com média 70 e desvio-padrão 8. Uma nota 86 possui $z = (86 - 70)/8 = 2$; uma nota 62 possui $z = -1$. Esses escores permitem comparar posições relativas em escalas diferentes. Se outra prova tem média 500 e desvio 50, a pontuação 600 também está a dois desvios acima do centro.




Figura 3.4: A média desloca a normal; o desvio-padrão controla sua abertura. Todas as curvas preservam área total igual a um.

O escore padroniza posição; não torna provas automaticamente equivalentes em conteúdo, dificuldade ou finalidade.

Aproximando pela regra 68–95, cerca de 95% dos valores do primeiro exemplo normal ideal estariam entre $70 - 2(8) = 54$ e $70 + 2(8) = 86$. Isso não significa que exatamente 95 de cada grupo de cem cairão no intervalo, nem que valores externos sejam erros. Significa que o modelo atribui aproximadamente 5% da área total às duas caudas, cerca de 2,5% em cada uma pela simetria. Em uma amostra pequena, a proporção observada pode diferir.

Um contraexemplo esclarece o limite: tempos de espera com muitas observações curtas e poucos casos extremamente longos costumam formar cauda à direita. Aplicar a normal apenas porque conhecemos média e desvio-padrão pode atribuir probabilidade a tempos negativos e subestimar casos extremos. A curva deve responder ao mecanismo e à forma observada. O escore z continua sendo uma padronização algébrica possível, mas a interpretação de áreas normais exige a hipótese adicional de distribuição aproximadamente normal.

Nem toda variável contínua é normal. Renda, tempo de espera e falhas podem ser assimétricos; dados limitados podem se acumular nas fronteiras; misturas de grupos podem gerar duas modas. Média e desvio-padrão não provam normalidade. Precisamos observar forma, processo e tamanho da amostra. A distribuição é um modelo útil quando suas implicações combinam com o fenômeno, não uma obrigação imposta pelo formato numérico.

Uniforme e normal também expressam incertezas diferentes. A uniforme declara a mesma densidade em todo o intervalo e fronteiras rígidas: fora de $[a, b]$, a probabilidade é zero. A normal concentra densidade perto de μ e possui caudas que, matematicamente, se estendem sem fronteira. Isso pode ser inadequado para variáveis impossíveis de serem negativas, sobretudo quando a média está perto de zero. Escolher distribuição significa comparar suporte, simetria, caudas e mecanismo, não apenas aproximar uma curva que pareça bonita sobre um histograma.

Síntese da trilha

Então, aluno, veja só o que você aprendeu aqui: na uniforme, intervalos de mesma largura possuem a mesma probabilidade. Na normal, a média localiza o sino e o desvio-padrão controla sua abertura. Ambas são modelos contínuos e precisam ser

justificadas pelo processo.

3.8 Covariância: quando duas variáveis se afastam juntas

Até agora, estudamos uma variável ou eventos combinados. Na análise exploratória, frequentemente perguntamos se duas quantidades variam juntas: mais horas de estudo acompanham notas maiores? maior tempo de espera acompanha satisfação menor? A covariância surgiu para resumir a direção dessa variação conjunta. Ela compara o sinal do desvio de X com o sinal do desvio correspondente de Y .

Antes de multiplicar desvios, desenhe ou leia a dispersão. O roteiro visual possui seis perguntas: qual direção predomina; quão apertados estão os pontos; a forma é aproximadamente linear ou curva; existem grupos separados; há observação influente; e uma terceira variável poderia explicar estratos diferentes? Esse checklist impede que a fórmula receba uma responsabilidade que não possui. Covariância resume direção líquida; ela não identifica sozinha curvatura, clusters ou erro de junção.

A galeria da Figura 3.5, apresentada adiante junto de Pearson, deve ser antecipada mentalmente aqui: produtos cruzados serão positivos nos quadrantes em que os dois desvios compartilham sinal e negativos quando possuem sinais opostos. Numa nuvem crescente, positivos tendem a dominar; numa decrescente, negativos. Numa curva em U simétrica, os sinais podem cancelar-se apesar de uma relação nítida. A conta nasce dessa geometria centrada nas médias.

Para uma amostra de pares (x_i, y_i) , a covariância amostral é

$$s_{XY} = \text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

n é a quantidade de pares; $\bar{x}$ e $\bar{y}$ são as médias; cada produto combina os desvios do mesmo caso. Se ambos são positivos ou ambos negativos, o produto é positivo. Se têm sinais opostos, o produto é negativo.

Use os pares horas de estudo e nota $(1, 2)$, $(2, 4)$, $(3, 5)$, $(4, 4)$ e $(5, 10)$. Primeiro calculamos

$$\bar{x} = \frac{1+2+3+4+5}{5} = \frac{15}{5} = 3,$$

$$\bar{y} = \frac{2+4+5+4+10}{5} = \frac{25}{5} = 5.$$

Em seguida, abrimos desvios, produtos e quadrados na tabela.

x_i	y_i	$x_i - 3$	$y_i - 5$	Produto	$(x_i - 3)^2$	$(y_i - 5)^2$
1	2	-2	-3	6	4	9
2	4	-1	-1	1	1	1
3	5	0	0	0	0	0
4	4	1	-1	-1	1	1
5	10	2	5	10	4	25
		0	0	16	10	36

A soma dos produtos centrados é $6 + 1 + 0 - 1 + 10 = 16$. Como tratamos os cinco pares como amostra,

$$s_{XY} = \frac{16}{5-1} = \frac{16}{4} = 4.$$

A covariância positiva indica que valores de X acima de sua média tendem a acompanhar valores de Y acima da média, e valores abaixo tendem a acompanhar valores abaixo. O par $(4, 4)$ produz -1 porque estudo está acima da média e nota abaixo.

Se os produtos negativos dominassem, a covariância seria negativa: quando uma variável estivesse acima do centro, a outra tenderia a ficar abaixo. Uma covariância próxima de zero indicaria ausência de variação conjunta linear evidente, mas poderia esconder relações curvas ou grupos diferentes. O sinal é informativo; a magnitude depende das unidades.

Neste exemplo, horas multiplicadas por pontos formam a unidade da covariância. Se horas forem convertidas em minutos, todos os desvios de X serão multiplicados por 60 e a covariância também. O fenômeno não mudou, mas o número mudou de escala. Para comparar relações em unidades diferentes, precisamos padronizar a covariância pelos desvios-padrão.

Façamos um exemplo resolvido com direção negativa. Considere tempo de espera $X = (1, 2, 3, 4)$ e satisfação $Y = (10, 8, 6, 4)$. As médias são $\bar{x} = 2,5$ e $\bar{y} = 7$. Os desvios de X são $(-1,5, -0,5, 0,5, 1,5)$; os de Y são $(3, 1, -1, -3)$. Os produtos correspondentes são $-4,5, -0,5, -0,5$ e $-4,5$, cuja soma é -10 . Logo,

$$s_{XY} = \frac{-10}{4-1} = -\frac{10}{3} \approx -3,33.$$

O sinal negativo aparece porque esperas abaixo da média acompanham satisfações acima da média e vice-versa. A unidade é minuto vezes ponto de satisfação.

Agora compare um conjunto com produtos que se cancelam. Para $X = (-2, -1, 1, 2)$ e $Y = (4, 1, 1, 4)$, ambas as médias já são 0 e 2,5, respectivamente. Os produtos centrados são $(-2)(1,5) = -3$, $(-1)(-1,5) = 1,5$, $(1)(-1,5) = -1,5$ e $(2)(1,5) = 3$. A soma é zero, então a covariância é zero. Contudo, Y depende claramente de $|X|$: valores extremos de X acompanham valores altos de Y . Este contraexemplo mostra que covariância zero não significa ausência de relação; significa ausência de movimento conjunto linear líquido nesse arranjo.

Também podemos enxergar por que deslocar a origem não muda a covariância. Se somarmos cem a todos os valores de X , a nova média também aumenta cem e cada desvio $x_i - \bar{x}$ permanece igual. Já multiplicar X por sessenta multiplica seus desvios e a covariância por sessenta. Assim, a covariância ignora a escolha do zero, mas não é imune à escolha da unidade. Essa propriedade prepara a normalização feita por Pearson.

A ordem dos pares jamais pode ser perdida. Se ordenarmos separadamente as horas e as notas, fabricaremos correspondências que não pertencem aos estudantes observados e provavelmente aumentaremos a covariância. Cada produto $(x_i - \bar{x})(y_i - \bar{y})$ deve usar as duas características da mesma unidade. Essa exigência conecta estatística à qualidade dos dados: identificadores, junções e granularidade determinam se os pares representam relações reais ou combinações acidentais. Antes da fórmula, confira que uma linha corresponde a uma unidade coerente.

Síntese da trilha

Então, aluno, veja só o que você aprendeu aqui: covariância multiplica desvios correspondentes. Produtos positivos indicam movimento no mesmo sentido; negativos, sentidos opostos. Sua escala depende das unidades, por isso ela prepara, mas não encerra, a medida de associação.

3.9 Correlação de Pearson e a síntese da associação linear

A correlação de Pearson, associada ao desenvolvimento da estatística moderna no fim do século XIX, padroniza a covariância pelos desvios-padrão de X e Y :

$$r = \frac{s_{XY}}{s_X s_Y}.$$

r é a correlação amostral; s_{XY} é a covariância amostral; s_X e s_Y são os desvios-padrão amostrais. O resultado fica entre -1 e 1 . O sinal indica direção e o valor absoluto indica força da associação linear.

Usaremos as somas da tabela. Para X , a soma quadrática é 10:

$$s_X^2 = \frac{10}{5-1} = \frac{10}{4} = 2,5, \quad s_X = \sqrt{2,5} \approx 1,581.$$

Para Y , a soma quadrática é 36:

$$s_Y^2 = \frac{36}{4} = 9, \quad s_Y = \sqrt{9} = 3.$$

Já obtivemos $s_{XY} = 4$.

Substituímos na fórmula:

$$r = \frac{4}{(1,581)(3)} = \frac{4}{4,743} \approx 0,843.$$

O valor indica associação linear positiva forte neste pequeno conjunto: maiores horas tendem a acompanhar maiores notas. A palavra “tendem” preserva a variação; o par $(4, 4)$ mostra que a relação não é perfeita.

Podemos obter o mesmo resultado diretamente das somas centradas:

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} = \frac{16}{\sqrt{10 \times 36}} = \frac{16}{\sqrt{360}} \approx \frac{16}{18,974} \approx 0,843.$$

Os divisores $n - 1$ se cancelam porque aparecem na covariância e nos dois desvios.

Uma correlação $r = 1$ representa pares exatamente sobre uma reta crescente; $r = -1$, sobre uma reta decrescente; r próximo de zero indica pouca associação *linear*. A palavra linear é indispensável. Se $Y = X^2$ e X assume valores simétricos negativos e positivos, a relação é perfeitamente determinada e curva, mas Pearson pode ficar próximo de zero. Um gráfico de dispersão deve acompanhar a correlação para revelar forma, grupos e pontos influentes.

A Figura 3.5 coloca quatro situações lado a lado: tendência positiva, tendência negativa, relação não linear e conjunto dominado por um ponto influente. A intenção não é




Figura 3.5: Quatro dispersões que exigem ler forma, direção e influência antes de resumir com Pearson.

estimar o coeficiente apenas pela aparência, mas aprender quais perguntas o coeficiente isolado não responde.

Nos dois painéis superiores da Figura 3.5, uma reta resume razoavelmente a direção, positiva ou negativa. No painel inferior esquerdo, há relação perfeita e previsível, mas simétrica e curva; produtos positivos e negativos podem cancelar-se, deixando r próximo de zero. No inferior direito, seis pontos formam uma nuvem quase horizontal, enquanto um único ponto distante cria uma tendência positiva aparente. Portanto, sempre associe r ao gráfico, ao tamanho da amostra e a uma análise de sensibilidade.

Um exemplo curto mostra a invariância de escala. Se a correlação entre altura em metros e massa em quilogramas é 0,70, converter altura para centímetros multiplica desvios e desvio-padrão por cem; numerador e denominador de r recebem o mesmo fator, que se cancela. A covariância muda, mas a correlação permanece 0,70. Se invertermos a variável, usando “déficit para uma meta” no lugar de altura, o sinal pode mudar porque a definição mudou, não porque o fenômeno físico se alterou.

Como contraexemplo causal, vendas de sorvete e ocorrências de insolação podem apresentar correlação positiva. Aumentar sorvete não precisa causar insolação; temperatura elevada aumenta simultaneamente consumo e exposição ao calor. Temperatura é uma explicação comum, ou variável de confusão. O coeficiente descreve o padrão observado, mas não escolhe entre “ X causa Y ”, “ Y causa X ”, “uma terceira variável causa ambos” ou “o padrão surgiu por seleção e acaso”. Essa escolha exige desenho e evidência adicionais.

A associação também não estabelece causalidade. No exemplo, horas e notas podem estar conectadas porque estudar ajuda, mas podem compartilhar outras causas: conhecimento prévio, disponibilidade de tempo, saúde, método de estudo ou dificuldade da avaliação. A covariância e a correlação descrevem como os pares observados variam juntos; não demonstram que alterar X produzirá mudança em Y . Para sustentar causalidade,

precisamos de desenho de pesquisa, temporalidade, controle de explicações alternativas e evidência adicional.

Um único ponto pode alterar bastante r . No conjunto, (5, 10) contribuiu com produto 10 e quadrado 25 em Y . Removê-lo sem justificativa mudaria a correlação; mantê-lo sem investigar também pode esconder erro. A análise responsável identifica a observação, verifica sua origem e comunica sensibilidade. O número resumido não substitui a leitura dos pares.

O tamanho da amostra modifica a força da evidência, ainda que não apareça explicitamente no valor final de r . Uma correlação 0,84 em cinco pares é mais instável do que o mesmo valor em quinhentos pares bem amostrados. Além disso, restringir artificialmente a faixa de X pode reduzir a correlação, e misturar grupos pode criá-la ou invertê-la. Por isso relatamos n , população, período e critérios de inclusão junto do coeficiente. A correlação é um resumo do conjunto analisado, não uma propriedade eterna das duas palavras usadas como nomes de coluna.

Também devemos interpretar o sinal conforme a definição das variáveis. Se Y for “nota”, sinal positivo pode parecer desejável; se Y for “quantidade de erros”, o mesmo sinal descreve aumento conjunto com um resultado indesejado. Inverter uma escala, como trocar satisfação por insatisfação, inverte o sinal sem alterar a estrutura dos pares. O coeficiente não conhece valor, finalidade ou ética: essas dimensões pertencem à pergunta e à leitura humana.

Explicação guiada

Aluno, preste atenção aqui: correlação de Pearson mede força e direção de uma associação linear padronizada. Ela não mede toda forma de relação e não prova causa. Sempre leia o gráfico, o processo que gerou os dados e as observações que mais influenciam a conta.

O capítulo percorreu uma única história. Variância e desvio-padrão lembraram que dados variam. Experimento, espaço e evento organizaram possibilidades. União, interseção, condicional e independência mostraram como combinar informação. Variáveis aleatórias e esperança transformaram resultados em resumos. Distribuições nomearam mecanismos recorrentes. Covariância e correlação voltaram ao observado para medir movimento conjunto.

Essas contas serão reutilizadas na próxima etapa da trilha. Na regressão linear simples com intercepto, quando quisermos descrever uma reta $\hat{Y} = \beta_0 + \beta_1 X$ pelos mesmos pares, a inclinação estimada poderá ser escrita como

$$\hat{\beta}_1 = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

A razão compara quanto X e Y se movem juntos com quanto X varia por si. Não resolveremos regressão aqui; a fórmula apenas revela por que covariância, variância e médias foram construídas com tanto cuidado.

Sob condições específicas — regressão linear simples, com intercepto, avaliada nos mesmos dados — o coeficiente de determinação satisfaz $R^2 = r^2$. A condição é essencial. A identidade não vale automaticamente para toda regressão, validação externa ou modelo sem intercepto. No capítulo seguinte, retomaremos a mesma tabela de desvios para transformar associação em reta, calcular resíduos e perguntar se a forma linear é realmente adequada.

Uma última nota impede a antecipação de virar atalho. Correlação alta não garante bom modelo preditivo fora da amostra; uma relação curva pode ser previsível e ter Pearson baixo; uma variável pode estar disponível somente depois do resultado e causar vazamento. A ponte Cov / Var explica a álgebra da reta simples, não substitui desenho, separação temporal, diagnóstico visual ou avaliação.

Na continuidade da trilha, IA utilizará essa base para compreender modelos de regressão e classificação; AED utilizará a mesma base para escolher gráficos, investigar distribuições e evitar narrativas causais indevidas. Em ambas, as fórmulas terão o mesmo papel: tornar explícita uma pergunta, permitir uma conta verificável e sustentar uma interpretação proporcional à evidência.

Síntese da trilha

Então, aluno, veja só o que você construiu: probabilidade não é palpite com porcentagem, distribuição não é curva escolhida por hábito e correlação não é causalidade. Cada resultado nasceu de um espaço, de condições, de operações conferíveis e de uma interpretação limitada ao que o modelo sustenta.