Análise Exploratória de Dados

Capítulo 10 — Text-to-SQL e NL2Vis

Cayo Oliveira

Sumário

10 Text-to-SQL e NL2Vis: da pergunta ao gráfico auditável **3**
10.1 Desambiguar intenção, métrica e população 3
10.2 Construir plano analítico antes de SQL 4
10.3 Executar uma EDA independente e produzir o gráfico 4
10.4 Recomendar visual e construir narrativa sem exagero 6
10.5 Roteiro de 180 minutos e evidência de aprendizagem 6

Capítulo 10

Text-to-SQL e NL2Vis: da pergunta ao gráfico auditável

A coordenação pergunta: “quais cursos estão com desempenho melhor?” A frase parece clara até a equipe descobrir que “melhor” pode ser aprovação, média, evolução, equidade ou persistência; período e denominador também não foram definidos. Um LLM pode produzir SQL e um gráfico atraentes, mas a primeira responsabilidade é converter a pergunta em contrato analítico.

Text-to-SQL traduz linguagem natural em consulta; NL2Vis propõe visualização. As duas tarefas compartilham a interpretação da pergunta, mas possuem erros diferentes. SQL válido pode usar métrica errada; um gráfico esteticamente correto pode ocultar período, amostra ou incerteza. Por isso, a trilha mantém intenção, métrica, consulta, resultado e visual conectados.

O caso de aula usa um conjunto sintético de resultados estudantis com curso, período, frequência, nota e situação. Nenhum resultado deve ser interpretado como diagnóstico de pessoas reais. A equipe compara aprovação por curso, depois questiona se a média esconde grupos pequenos e se a comparação é justa.

Em três horas, passamos de pergunta ambígua a especificação, catálogo de campos, plano de consulta seguro, agregação independente, gráfico e narrativa. O modelo pode sugerir cada etapa, mas os alunos verificam campo, filtro, denominador e significado antes de apresentar uma conclusão.

10.1 Desambiguar intenção, métrica e população

Uma pergunta analítica é decomposta em entidade, medida, dimensão, período, filtro, comparação e decisão. “Desempenho melhor” não é métrica; “taxa de aprovação por curso no período X” já explicita parte do contrato, embora ainda exija definição do que conta como aprovação e do denominador elegível.

A turma escreve duas interpretações legítimas e prevê como a decisão mudaria. Se a gestão quer oferecer tutoria, taxa de reprovação e tendência podem ser úteis; se quer avaliar currículo, precisa considerar coorte, carga e oferta. A pergunta do usuário não determina sozinha o construto.

O LLM recebe glossário governado, tipos e definições necessárias. Não recebe CPF, nome ou coluna irrelevante. Um catálogo semântico apresenta nomes amigáveis e mapeia para colunas reais, unidades, grão e regra de agregação. Esse contrato reduz erro de ligação entre expressão e esquema.

O contraexemplo é aceitar “média por curso” sem saber se cada linha é estudante, matrícula ou avaliação. Uma junção pode duplicar registros e inflar denominador. Antes de agrupar, a equipe verifica grão, chave, duplicidade e política para dados ausentes.

10.2 Construir plano analítico antes de SQL

Antes de escrever consulta, a squad representa a intenção em um plano simples: métrica aprovada, dimensão, período, filtros, população, agregação, política de privacidade e visual pretendido. Essa camada intermediária permite inspecionar a interpretação antes de executar código.

O modelo pode preencher uma proposta JSON, mas o backend valida nomes contra uma allowlist, tipo de dado, operador permitido e limite de linhas. Campos desconhecidos são rejeitados; não são corrigidos silenciosamente para outra variável. Valores entram como parâmetros, não como concatenação livre.

Código da squad plano allowlisted para uma agregação

```
# Define somente dimensões e métricas aprovadas pela coordenação.
dimensoes = {"curso": "course", "periodo": "term"}
# Mantém um catálogo explícito de medidas analíticas autorizadas.
metricas = {"taxa_aprovacao": "passed", "nota_media": "score"}
# Recebe uma proposta estrutural, não SQL livre do modelo.
plano = {"dimensao": "curso", "metrica": "taxa_aprovacao", "periodo": "2026.1"}
# Interrompe o fluxo quando a dimensão não consta no catálogo.
assert plano["dimensao"] in dimensoes
# Interrompe o fluxo quando a métrica não foi aprovada.
assert plano["metrica"] in metricas
# Mostra a interpretação antes de gerar consulta ou visual.
print("Plano aceito para revisão:", plano)
```

Esse protótipo verifica nomes, não autorização completa ou correção semântica. A equipe adiciona autenticação no servidor, valida período e aplica limiar mínimo de grupo. Em produção, SQL pode ser gerado a partir do plano com biblioteca conhecida ou selecionado entre consultas revisadas.

O plano também funciona como explicação acessível à pessoa usuária. A interface apresenta “taxa de aprovação por curso no período 2026.1” para confirmação ou correção antes da execução. Essa etapa diminui risco de resolver com precisão uma pergunta diferente da pretendida.

10.3 Executar uma EDA independente e produzir o gráfico

Uma vez aprovado o plano, o conjunto é filtrado e agregado com código determinístico. O gráfico resulta de tabela já conferida, não de um código livre que o LLM executa. A turma compara contagens e proporções antes de escolher um visual.

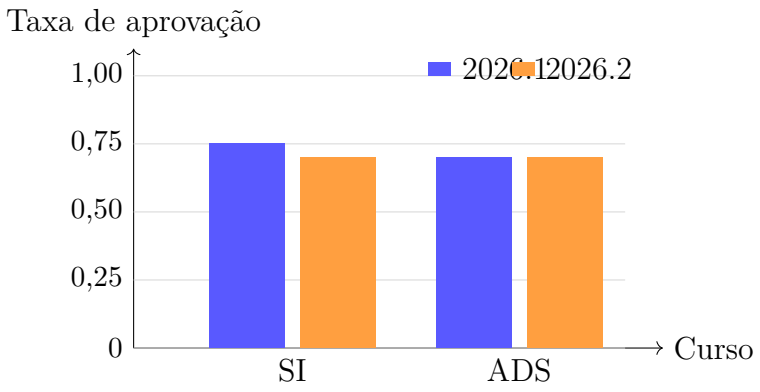

O esboço mostra duas comparações próximas e reforça que o denominador deve acompanhar a barra. No exemplo visual, pequenas diferenças podem não ser estáveis; não colocamos ordenação dramática nem anotação causal. A saída do código e este desenho devem concordar antes da comunicação.

Código da squad tabela, denominador e barras com intervalo

```
# Importa pandas para resumir o conjunto sintético em uma tabela.
import pandas as pd
# Importa matplotlib para gerar um visual reproduzível.
import matplotlib.pyplot as plt
# Cria observações sintéticas; cada linha representa uma matrícula.
dados = pd.DataFrame({"curso": ["SI", "SI", "ADS", "ADS", "SI", "ADS"],
                      "aprovado": [1, 0, 1, 1, 1, 0],
                      "periodo": ["2026.1"] * 6})
# Filtra o período definido no plano analítico.
recorte = dados.loc[dados["periodo"].eq("2026.1")].copy()
# Calcula total elegível e aprovações por curso.
resumo = recorte.groupby("curso")["aprovado"].agg(["sum", "count", "mean"])
# Exibe numerador e denominador antes da interpretação.
print(resumo)
# Cria barras para comparar proporções, não volume bruto.
ax = resumo["mean"].plot(kind="bar", color="#2463A6", ylim=(0, 1))
# Rotula a medida e o universo temporal de forma explícita.
ax.set_ylabel("Proporção aprovada entre matrículas do período")
# Nomeia o gráfico sem declarar causalidade.
ax.set_title("Aprovação observada por curso  dado sintético")
# Ajusta margens para preservar rótulos na exportação.
plt.tight_layout()
# Exibe o visual para revisão de forma e dados.
plt.show()
```

Com amostra tão pequena, as proporções são instáveis. A visualização é um exemplo de código e não uma conclusão institucional. Em um dataset real, incluiríamos intervalo de incerteza, distribuição por coorte e tamanho mínimo antes de comparar ou expor grupos.

O painel informa filtros, data, fonte, definição e atualização. Se a pessoa alterar o período, a tabela e gráfico são recalculados pela mesma consulta identificada. Um texto gerado sem vínculo a esses parâmetros pode sobreviver a uma mudança de filtro e ficar incorreto.

10.4 Recomendar visual e construir narrativa sem exagero

NL2Vis escolhe codificação de acordo com a pergunta. Comparar categorias pede barras ordenadas; tendência temporal pede linha; distribuição de notas pode usar histograma ou boxplot; relação entre presença e resultado pode usar dispersão, com cautela quanto à associação. O modelo pode propor, mas o analista explica por que o canal visual serve à tarefa.

Storytelling começa pela evidência: público, contexto, observação, limite e ação possível. “Curso X tem o maior valor” não autoriza dizer que o curso causa o desempenho. A equipe substitui linguagem causal por descrição associativa e apresenta o tamanho da amostra.

Uma boa Big Idea pode ser: “neste recorte sintético, a diferença observada merece ser verificada por coorte antes de orientar apoio”. O visual mostra a comparação; a tabela oferece denominadores; a nota explica que seis matrículas não sustentam uma decisão real.

O contraexemplo usa eixo truncado e remove grupo pequeno para criar sensação de grande diferença. Outra falha é ordenar categorias alfabeticamente quando a pergunta é ranking. A revisão olha escala, rótulos, contraste, incerteza, legenda e acessibilidade.

10.5 Roteiro de 180 minutos e evidência de aprendizagem

19h19h25: grupos esclarecem pergunta e escrevem contrato de métrica. 19h2519h50: inspecionam esquema, grão e ausências. 19h5020h20: montam plano semântico e analisam SQL proposto. 20h2020h30: verificam denominador e registram dúvida antes da chamada.

20h3021h: executam agregação determinística e conferem tabela. 21h21h25: escolhem gráfico e visualizam recorte. 21h2521h45: redigem narrativa com limite e recomendação condicional. 21h4522h: outra equipe altera período e tenta reproduzir o resultado.

O artefato contém pergunta, plano, consulta ou código, tabela, gráfico, fonte, versão, denominador e texto final revisado. A avaliação exige rastreabilidade entre todos os elementos. Se o estudante não consegue refazer a conta, a resposta do modelo não é evidência suficiente.

O Capítulo 11 compara plataformas de BI e ambientes de execução. A mesma definição de métrica será usada para avaliar copilotos e agentes, sem deixar interface de fornecedor ocultar acesso, semântica e trilha de auditoria.

Síntese da trilha

Text-to-SQL e NL2Vis aceleram tradução, mas não definem a pergunta nem validam significado. A cadeia segura é contrato analítico, plano permitido, cálculo reproduzível, visual escolhido por tarefa e storytelling proporcional à evidência.