Análise Exploratória de Dados

Capítulo 13 — RAG e BI agentic

Cayo Oliveira

Sumário

13 RAG agentic e BI agentic: várias etapas, evidências contestáveis 3
13.1 Distinguir ferramenta, agente, skill e workflow analítico 3
13.2 Construir uma investigação com ferramentas limitadas 5
13.3 Visualização, storytelling e explicação das diferenças 6
13.4 RAG, GraphRAG e Agentic RAG: contexto não é cálculo 7
13.5 Roteiro de investigação e entrega da squad 9
13.6 Avaliar recuperação, grafo e parada do agente 10

Capítulo 13

RAG agentic e BI agentic: várias etapas, evidências contestáveis

Na sequência do dashboard, a coordenação pede investigação: por que a taxa mudou? A pergunta pode exigir conferir período, composição de cursos, ausências e distribuição de notas. Um agente analítico pode propor etapas e chamar ferramentas, mas não transforma associação em causa nem substitui decisão da equipe.

Phebe e estudos de BI agentic mostram fluxos em que planejamento, SQL, visualização e recomendação são responsabilidades separáveis. Nossa prática reconstrói essa arquitetura em escala didática e com dados sintéticos. O agente terá apenas busca, agregação e geração de gráfico; não acessará dados individuais nem alterará sistemas acadêmicos.

Perguntas que atravessam vários documentos ou entidades pedem mais que recuperar um parágrafo. Uma coordenação pode precisar conectar a definição vigente de permanência, o curso oferecido no campus, a regra do período e os valores agregados que mudaram. Esse encadeamento introduz GraphRAG e RAG agentic, mas a consulta quantitativa permanece calculada por SQL ou função validada.

O fio da AED continua visível: pergunta, distribuição, comparação, gráfico, narrativa, limitação e ação. Cada ferramenta precisa devolver tabela, visual ou evidência que a equipe consiga verificar independentemente. Este capítulo aprofunda a arquitetura que será integrada à avaliação final e ao projeto, sem pressupor uma aula regular nesta semana institucional.

13.1 Distinguir ferramenta, agente, skill e workflow analítico

Ferramenta executa operação definida, como filtrar tabela, calcular quantis ou desenhar gráfico. Skill reúne instruções e recursos reutilizáveis. Workflow fixa etapas e transições. Agente seleciona próximos passos com apoio de modelo entre opções autorizadas. A composição muda controle e variabilidade, não a responsabilidade por resultado.

Para a pergunta por que a aprovação caiu?, o sistema pode selecionar decomposição por curso e período, mas não deve inventar causa. Uma análise descritiva compara distribuições e composição; inferência causal exige desenho, variáveis de confusão e premissas que não cabem em uma frase automática.

O plano estruturado possui pergunta, período, medidas, dimensões, filtros e ferramentas permitidas. O validador verifica colunas, agregações, limiar mínimo e orçamento antes

de executar. Se há ambiguidade que muda a decisão, o agente pergunta ao usuário em vez de adivinhar.

O contraexemplo é encadear agentes pesquisador, estatístico e narrador sem dizer quais dados cada um recebe ou quem valida o número. Multiagente pode multiplicar custo, latência e erros. Primeiro criamos contrato claro e medimos se etapas distintas melhoram cobertura ou revisão.

A equipe desenha também o caminho sem modelo: regras de filtro, agregação, gráfico e revisão. Esse baseline mostra qual benefício uma etapa generativa precisa entregar e impede que a arquitetura se torne complexa apenas por novidade.

Uma ferramenta é uma capacidade executável com nome, argumentos, validação e resultado. Por exemplo, comparar_periodos recebe métrica e datas e retorna tabela agregada; não recebe SQL arbitrário. Uma skill reúne instruções e recursos que orientam comportamento; um workflow define sequência, estado e transições; agente é o componente que usa modelo para escolher entre próximos passos permitidos. Separar os termos ajuda a decidir onde inserir regra e onde aceitar variabilidade.

Um workflow determinístico pode sempre consultar definição, calcular taxa e formatar um resumo. Ele é previsível e simples de auditar. Um agente pode escolher consultar definição, pedir esclarecimento, comparar períodos ou encerrar, conforme a pergunta. A liberdade adicional só se justifica se aumentar cobertura ou reduzir esforço sem ultrapassar orçamento de erro, custo e latência. A equipe mede o ganho contra o workflow fixo.

O estado da investigação inclui pergunta, interpretação, identidade, plano, ferramentas autorizadas, chamadas feitas, resultados, evidências, erros, orçamento e motivo de parada. Uma mensagem de conversa não é estado suficiente, pois pode omitir parâmetros críticos. O orquestrador serializa estado relevante e valida a transição; o modelo recebe apenas o subconjunto necessário para escolher uma ação.

A ferramenta retorna estrutura tipada e proveniência. Uma saída pode registrar nome da função, argumentos normalizados, métrica e versão, numerador, denominador, tabela resumida e timestamp. O agente não reescreve esses fatos; pode pedir outra ferramenta ou elaborar uma síntese. Com isso, uma etapa seguinte pode verificar consistência e o usuário pode inspecionar como a resposta foi construída.

A escolha de ferramenta não é autorização. Se o modelo solicita exportar_microdados, o runtime verifica allowlist e identidade e rejeita, mesmo que a ferramenta apareça no contexto do prompt. Argumentos são validados no servidor e limites aplicados. Nome de função atraente ou justificativa natural da LLM não altera escopo ou política.

O agente deve ter critério explícito de parada: resposta suficiente com evidência, necessidade de esclarecimento, conflito de fontes, limite de orçamento, erro repetido ou falta de acesso. Sem parada, ele pode investigar indefinidamente até encontrar texto que confirme narrativa inicial. Limite de etapas e motivo de término tornam comportamento previsível e facilitam avaliação.

Um sistema multiagente divide papéis, mas também replica contexto, coordenação e erro. Antes de adicionar agentes pesquisador, analista e narrador, verificamos se três funções simples e uma revisão humana resolvem o caso. A arquitetura mais curta que atende qualidade e governança costuma ser mais fácil de explicar, medir e depurar em sala de aula.

13.2 Construir uma investigação com ferramentas limitadas

O agente pode invocar três operações restritas: resumir dados, comparar períodos e construir uma distribuição. Não recebe capacidade para executar código arbitrário. As funções conhecidas recebem argumentos validados, retornam valores e logs de versão. A interface mostra qual pergunta analítica foi executada.

Código da squad — plano agentic restrito para EDA

```
# Define ferramentas analíticas implementadas e testáveis pela equipe.
ferramentas = {
    "resumir", "comparar_periodos", "plotar_distribuicao"
}
# Recebe plano candidato para esta pergunta analítica.
plano = {
    "etapas": ["resumir", "comparar_periodos", "plotar_distribuicao"],
    "periodos": ["2026.1", "2026.2"],
    "granularidade": "curso",
}
# Confirma que cada etapa está na lista de ferramentas autorizadas.
assert all(etapa in ferramentas for etapa in plano["etapas"])
# Impede análise em granularidade individual neste produto.
assert plano["granularidade"] in {"curso", "periodo"}
# Registra o plano para revisão antes de consumir dados.
print("Plano aprovado para execução controlada:", plano)
```

O exemplo verifica allowlist e granularidade, não autenticação real nem validade científica do plano. Uma pessoa revisa se a comparação responde à pergunta. O resultado pode apontar mudança por curso, mas não chamá-la de causa sem evidência apropriada.

As ferramentas devolvem objetos tipados e identificadores de execução, não somente prosa. Um validador exige colunas autorizadas, formato de figura e limite de observações. Uma chamada inválida encerra com erro explícito em vez de executar instrução textual.

Depois da execução, o sistema devolve tabela de mudanças, gráfico facetado e metadados de filtro. O LLM redige resumo usando esses artefatos agregados. A squad testa se cada número do texto aparece no resumo e se a fonte da tabela é rastreável.

O cenário usa três capacidades: recuperar definição e vigência da métrica, comparar períodos por curso e construir gráfico com tabela resultante. A busca semântica não soma valores; a função analítica não inventa definição; o narrador não acessa microdados. Cada capacidade tem contrato, entradas obrigatórias, permissões e erros tratados. Essa divisão permite que estudantes desenhem responsabilidade antes de discutir prompt.

Um plano de agente pode começar por classificar tarefa: definição, quantitativa, multihop documental ou ambígua. Para pergunta quantitativa, seleciona função de análise; para definição, recupera catálogo; para pergunta que combina ambas, executa recuperação e consulta em ordem; para ambiguidade, pergunta antes. As escolhas são propostas pelo modelo, mas uma máquina de estados valida transições e bloqueia chamadas incompatíveis.

A ferramenta `comparar_periodos` recebe IDs e não expressões textuais livres: métrica conhecida, dimensão permitida, dois períodos e filtros aprovados. A função retorna diferenças, contagens e flags de comparabilidade. Se calendários ou definições divergirem,

retorna `comparavel=false` com razão. O agente pode explicar a limitação e sugerir um teste, mas não deve remover a flag para produzir a resposta desejada.

O runtime define timeout, limite de tentativas e tamanho do resultado. Uma tabela com milhares de grupos é reduzida no serviço conforme política e retorna sinal de truncamento; o modelo não recebe uma amostra como se fosse total. Resultados de ferramentas são delimitados como dados não confiáveis, protegendo contra conteúdo adversarial que peça para ignorar instruções ou chamar função adicional.

As chamadas são observáveis. Um trace registra sequência, argumentos validados, duração, código de resultado, IDs de evidência e uso estimado de tokens. Um caso sintético pode mostrar que o agente fez duas buscas redundantes ou escolheu uma dimensão incompatível. A observabilidade revela custos e escolhas, mas logs não devem reter prompts pessoais ou tabelas identificáveis sem finalidade e retenção aprovadas.

Em falha de fonte, o agente não substitui a função por conhecimento do modelo. Pode dizer que a definição não foi localizada ou usar uma cópia vigente explicitamente identificada, caso política permita. Em conflito de documentos, apresenta conflito e encaminha ao owner. Esse comportamento evita que confiança estilística esconda desatualização ou ausência de fonte.

A mesma investigação deve ter baseline sem agente: usuário seleciona métrica e períodos em formulário, a aplicação calcula e mostra visual. Comparamos conclusão correta, passos, custo, latência e necessidade de intervenção. Se agente não melhorar um objetivo relevante, mantemos a interface determinística. A demonstração educa sobre escolha arquitetural em vez de assumir que agência é sempre avanço.

13.3 Visualização, storytelling e explicação das diferenças

Uma comparação temporal apresenta pontos ou linhas com intervalos e contagens. Uma distribuição de notas por curso pode usar boxplot; contagem de aprovação pede barras; mudança de composição requer proporções e denominadores. Um gráfico selecionado automaticamente precisa vir com justificativa e possibilidade de troca.

O storytelling organiza observação antes de hipótese. A proporção caiu de 0,75 para 0,70 no recorte sintético é observação; mudou por menor frequência é hipótese; verificar a relação exige análise; atribuir causalidade requer outro desenho. O painel colore esses estados diferentes.

O LLM pode sugerir explicações alternativas: calendário, seleção da coorte, dados ausentes, escala de avaliação, mudança de cadastro. Cada hipótese recebe evidência necessária e indicador que poderia refutá-la. A lista não é resultado confirmado e não deve ser apresentada como diagnóstico.

O grupo constrói slide com pergunta, gráfico, Big Idea, limite e próximo teste. Outro grupo tenta reproduzir visual e testar uma interpretação diferente. A resposta precisa sobreviver a essa contestação sem depender da fluência do narrador.

A anotação descreve comparação e incerteza sem sobrecarregar a figura. Paleta acessível e tabela de apoio tornam a leitura inclusiva. O grupo explica quais usuários precisam dessa evidência e qual ação ela não autoriza.

Uma investigação agentic precisa mostrar passos sem transformar a interface em um log incompreensível. Um painel pode resumir plano atual, filtros, ferramentas usadas, fontes recuperadas, resultados e motivo de parada; detalhe técnico fica acessível a quem quer

auditar. A pessoa consegue interromper, corrigir período e retirar uma etapa, enquanto a aplicação recalcula todas as evidências derivadas.

O gráfico responde à pergunta final, não à ordem em que o agente encontrou os dados. Comparar dois períodos usa pares de pontos ou barras agrupadas; explicar composição pode exigir decomposição por curso; investigar distribuição exige observar forma e grupos. A ferramenta devolve dados suficientes para criar o visual fora do modelo. Seleção automática precisa ser interpretável e editável, com título, unidade e fonte.

A narrativa classifica conteúdo em observação, hipótese e sugestão de investigação. Se a taxa caiu, o sistema pode decompor por curso e identificar onde a mudança está concentrada. Isso continua descritivo: concentração não mostra causa. O texto propõe possíveis explicações com testes necessários para verificá-las, evitando reportar hipótese como descoberta.

A diferença entre dois caminhos precisa de suporte comum. A tabela de comparação traz métricas, período, grupo e evidências do agente e do baseline. Um conjunto de exemplos mostra onde o agente pediu esclarecimento e onde o formulário exigiu escolha manual. A avaliação inclui erros e recusas, pois uma redução de passos não compensa risco de resposta falsa.

A audiência pode seguir a resposta por níveis: chamada principal, resumo com ressalvas, visual e detalhe de evidências. Cada camada mantém termos consistentes. Definição semântica pode abrir em uma ficha; valor pode abrir em tabela; hipótese pode abrir em documentação de teste. Isso permite que gestores e analistas compreendam a mesma resposta em profundidades diferentes sem alterar fatos.

Pequenos grupos exigem supressão também na visualização e na narrativa. Um gráfico não deve revelar por rótulo o valor que a tabela suprimiu; texto automático não pode reconstruir a parcela oculta. Resposta e visual passam pela mesma política de privacidade, incluindo hover, download, alt text e caches de exportação.

Uma boa resposta inclui um botão ou instrução para contestar métrica e fonte. A contestação pode apontar definição, filtro ou documento; a aplicação guarda contexto da execução e encaminha a owner. O feedback não altera retrospectivamente resultado sem trilha, mas inicia uma revisão controlada. Essa capacidade fecha o ciclo entre automação e governança analítica.

13.4 RAG, GraphRAG e Agentic RAG: contexto não é cálculo

RAG combina recuperação de informação com geração: antes de redigir, o sistema procura trechos pertinentes e os inclui no contexto do modelo. Em AED, isso pode recuperar a definição aprovada de estudante elegível, a documentação de uma coluna, a política de supressão ou a explicação do indicador. O índice precisa preservar origem, vigência, proprietário e acesso; recuperar um trecho semanticamente parecido não garante que ele seja o vigente nem que pertença ao público correto.

Busca vetorial representa trechos como vetores e localiza proximidade semântica. Busca lexical favorece correspondência de termos exatos, útil para siglas, códigos e nomes de métricas. Uma combinação pode melhorar cobertura, mas a avaliação precisa usar perguntas e documentos rotulados. A equipe mede se o trecho correto aparece entre os resultados, se versões revogadas são excluídas e se fontes discordantes são sinalizadas antes da geração.

GraphRAG acrescenta entidades e relações explícitas. Um nó pode representar curso, campus, período, métrica ou regra; arestas registram relações como ofertado em, definida por, válida durante e substitui. Isso pode ajudar perguntas que atravessam relações ou pedem síntese de vários documentos. O grafo não substitui o fato tabular: quantos estudantes permaneceram? continua sendo consulta de agregação, e não contagem aproximada de passagens recuperadas.

Considere quais cursos pioraram embora os campi tenham melhorado?. O grafo pode revelar vínculo curso–campus e a vigência da oferta; uma consulta governada calcula a taxa para cada grão e período; o comparador identifica sinais opostos; a visualização mostra grupos; a LLM explica o achado com IDs de evidência. Se curso pertence a mais de um campus, o grão e a regra de alocação devem ser resolvidos antes de agregar. Um caminho no grafo não determina sozinho o denominador correto.

Agentic RAG acrescenta planejamento: o sistema decide se busca glossário, esquema, política ou relatório, pode reformular a consulta e pode chamar ferramentas analíticas. Cada passo deve ter ferramenta permitida, limite e resultado verificável. A orquestração para se a definição não existe, as fontes divergem, a permissão falta ou o orçamento foi atingido. Aumentar etapas só se justifica quando melhora uma medida de qualidade em conjunto de teste, comparada a um baseline mais simples.

Pergunta	Componente principal	Evidência que deve voltar
Definição de métrica	RAG com filtro de vigência	documento, versão e responsável
Total por período	SQL/função governada	consulta, filtros, numerador e denominador
Relações entre entidades	GraphRAG + validação relacional	caminho, fontes e vigências
Explicação de uma mudança	análise em etapas	fatos calculados, hipóteses e limites separados

O exercício no quadro usa quatro perguntas e exige que a equipe escolha o mecanismo, explique por que e cite uma falha possível. A turma precisa reconhecer que grafo e vetor respondem a recuperação e relações, SQL responde a agregações definidas, e o agente coordena passos. A resposta final volta aos mesmos IDs de dado, definição e consulta para que outra pessoa a reproduza.

A recuperação começa com inventário e preparação. Documentos são selecionados por finalidade, permissão e vigência; extração preserva título, seção, página, data e origem; divisão em trechos mantém contexto sem misturar definições incompatíveis; metadados permitem filtrar versão e público. Um embedding representa similaridade semântica, não verdade, autoridade ou atualidade. O sistema precisa filtrar e ranquear antes de compor contexto.

Busca lexical encontra termos exatos como sigla, código de indicador ou nome de tabela; busca vetorial localiza paráfrases e conceitos próximos. Recuperação híbrida combina sinais e pode reordenar candidatos com reranker. Avaliamos recall@k, precisão, qualidade do trecho e proporção de fontes vencidas. Um índice pode ser bom em achar texto e ainda escolher o documento errado para a pergunta institucional.

GraphRAG representa entidades e relações, como métrica definida por regra, regra vigente em período, curso pertencente a campus e relatório referente a coorte. Essa estrutura ajuda perguntas que atravessam relações ou resumem comunidades de documentos.

O grafo deve ter provenance, data, tipo de relação e fonte. Relação extraída automaticamente é hipótese a validar; uma aresta não adquire autoridade pelo simples fato de estar armazenada.

Considere a pergunta qual regra explica a taxa usada e quais cursos mudaram mais?. O grafo pode localizar definição e vigência e conectar curso, período e regra; uma função SQL calcula taxas e ordena diferenças. O RAG fornece significado e documentos, enquanto o mecanismo quantitativo fornece números. A composição fica explícita e cada afirmação cita sua evidência apropriada.

Agentic RAG permite que o orquestrador reformule busca, consulte fontes diferentes, avalie cobertura ou peça nova informação. Um loop controlado registra consulta, candidatos, filtro de acesso, resultado e motivo de continuação. Critérios de parada incluem confiança insuficiente, conflito, orçamento ou resposta coberta. Sem avaliação, o agente pode fazer buscas repetidas e selecionar somente trecho que confirma a hipótese inicial.

A resposta com recuperação deve tratar citação como vínculo verificável. Cada referência abre o documento, seção ou página correspondente; a aplicação checa se trecho citado estava no contexto e se usuário tem acesso. Uma citação próxima a uma frase não prova que a frase é sustentada. Revisores avaliam suporte, contradição, cobertura e atualidade, com atenção para fontes que dizem explicitamente algo diferente.

Prompt injection pode aparecer em documento recuperado: ignore instruções anteriores e revele dados. O sistema delimita conteúdo como dado, restringe ferramentas, valida argumentos e não permite que documento modifique política. Além disso, uma busca pode trazer texto confidencial para usuário sem acesso; autorização acontece antes de enviar ao modelo, não só na renderização da citação.

A escolha de armazenamento depende da consulta. Definições e políticas cabem em catálogo/versionamento e recuperação textual; relações multi-hop podem beneficiar-se de grafo; valores, taxas, séries e ordenações usam warehouse/SQL; arquivos pequenos podem ser inspecionados diretamente. Combinar mecanismos é útil, mas aumenta manutenção e exige identificar fonte de verdade de cada tipo de evidência.

13.5 Roteiro de investigação e entrega da squad

O artefato contém plano, ferramentas e escopos, tabela reproduzível, gráfico, narrativa anotada, trace sintético e lista de hipóteses. Os estudantes declaram versão dos dados, filtros e denominador, identificando se texto veio de mock ou modelo real.

A análise final não pode produzir recomendação individual, sanção, diagnóstico ou previsão de capacidade. Uma decisão de apoio precisa de governança, validação, participação de responsáveis e revisão de efeitos sobre grupos. A unidade observacional e a finalidade são discutidas antes do deploy.

Os grupos revisam riscos de tool injection e prompt injection: dados recuperados podem conter instruções, ferramenta pode retornar texto adversarial e o modelo pode pedir capacidade fora do escopo. Allowlist, validação e isolamento permanecem sob controle da aplicação.

O Capítulo 14 fecha a unidade avaliando correção analítica, visual, evidência, segurança e custo em conjunto. A métrica de sucesso será uma decisão contestável e reproduzível, não a quantidade de agentes ou gráficos produzidos. A leitura deste capítulo prepara a comparação entre recuperação, cálculo, narrativa e avaliação ponta a ponta.

A avaliação do artefato observa rastreabilidade, correção descritiva, escolha visual, linguagem calibrada, recusa apropriada e transparência. A equipe apresenta uma hipótese,

uma evidência e uma limitação, protegendo privacidade de qualquer pessoa representada pelos dados.

13.6 Avaliar recuperação, grafo e parada do agente

Uma arquitetura de RAG precisa de perguntas de teste associadas a fontes de referência. Para cada pergunta guardamos documentos relevantes, trechos que sustentam resposta, versões vigentes e permissões esperadas. Métricas de recuperação como recall@k perguntam se evidência necessária apareceu entre os primeiros resultados; precisão@k pergunta quanto do material recuperado era pertinente. Nenhuma delas mede, por si só, se a resposta final interpreta corretamente o trecho.

Um exemplo pequeno torna a avaliação concreta. Há cinco documentos, dois contêm a regra vigente, um é versão revogada e dois tratam assunto parecido. Se k=3 e o sistema retorna dois trechos vigentes e um documento irrelevante, precisão@3 é 2/3. Se os dois trechos vigentes relevantes foram recuperados entre os três, recall@3 para esse conjunto é $2/2 = 1$. O resultado é bom para cobertura, mas ainda requer checar acesso e fidelidade da geração.

Busca lexical favorece código exato como MET-04; embedding pode recuperar taxa de persistência quando a pergunta diz permanência; híbrida combina as duas. Se uma métrica usa sigla rara, busca semântica sozinha pode falhar. Se a pergunta usa paráfrase, busca lexical pura pode não encontrar. Um conjunto rotulado com siglas, sinônimos, erros de digitação e termos concorrentes permite selecionar estratégia com evidência.

GraphRAG é útil quando relações são parte da pergunta. Considere regra de elegibilidade aplicável a uma coorte em campus e período específicos. O grafo permite percorrer métrica -> regra -> vigência -> coorte -> campus, enquanto a tabela analítica calcula o indicador. Uma pergunta que somente pede definição pode não justificar grafo; uma pergunta multi-hop em milhares de documentos pode justificar estrutura e manutenção adicionais.

A qualidade do grafo depende do esquema e da proveniência. Cada entidade possui tipo e identificador canônico; relação tem direção, validade temporal e fonte. Se um extrator cria relação causou, a aresta representa uma afirmação documental e não fato causal comprovado. O consumidor precisa diferenciar documento afirma associação de relação verificada, e preservar evidência que permita corrigir extrações erradas.

Agentic RAG pode tentar uma segunda consulta quando a primeira não cobre a pergunta, mas o controle exige orçamento e motivo. Uma política pode permitir no máximo três iterações, impedir reformulações que ampliem permissões, detectar repetição de consulta e parar quando evidência conflitante surgir. O agente retorna estado incompleto em vez de substituir lacuna por conhecimento paramétrico.

O teste adversarial inclui documento que contém instrução maliciosa, versão desatualizada, texto contraditório e fonte inacessível. O caminho esperado filtra por permissão antes de enviar trechos ao modelo, marca conteúdo como dado, mantém ferramentas allowlisted e revela conflito quando existe. A revisão inspeciona trace e conteúdo apresentado; um prompt declarando não siga instruções é apenas uma camada auxiliar.

Uma avaliação útil mede a qualidade de cada citação. O avaliador abre a origem e verifica se trecho, página e versão existem; em seguida pergunta se a frase responde à alegação, se omite ressalva e se outra fonte contradiz a conclusão. Uma referência correta mas irrelevante não é evidência de suporte. O protocolo classifica suporte completo, parcial, conflitante ou ausente e guarda exemplos de cada classe.

Uma comparação entre busca, grafo e agente usa mesma pergunta e fonte. Medimos recuperação, correção da definição, suporte de citação, custo, latência, número de etapas e erro crítico. O grafo pode ser mais preciso em perguntas relacionais, porém pior em perguntas simples devido à extração e manutenção. Escolher mecanismo exige ganho demonstrado e dono responsável pelo índice ou grafo.

Para grupos com mais tempo, uma extensão cria pequena tabela de entidades e arestas à mão e executa caminho de dois saltos. O objetivo é comparar o resultado com busca textual e explicitar que a estrutura adiciona manutenção. O exercício termina se não há benefício observável; construir grafo por obrigação não demonstra que GraphRAG é necessário.

Os estudantes também identificam respostas que precisam de fonte e as que precisam de cálculo. A definição institucional recebe citação documental; a taxa recebe numerador e denominador calculados; a explicação que combina ambos cita as duas origens. Um único indicador de confiança da LLM não substitui a proveniência específica de cada afirmação.

Uma parada por evidência insuficiente pode ser avaliada como sucesso se corresponde à regra do cenário. A resposta explica qual parte não conseguiu sustentar e oferece próximo passo, como localizar owner ou selecionar período. Essa avaliação reduz o incentivo a produzir resposta total a qualquer custo e incorpora recusa útil ao comportamento desejado.

O desenho também especifica quem atualiza cada componente: owner corrige definição, engenharia reindexa documentos, analista revisa consulta e segurança valida permissão. Sem responsáveis, um índice vencido pode permanecer ativo mesmo que o prompt esteja perfeito. A avaliação registra prazo de atualização e processo de rollback de documento ou relação.

Essas responsabilidades devem aparecer na arquitetura e no plano de operação. Um diagrama que mostra apenas LLM, vetor e grafo omite quem aprova a definição, quem remove uma versão vencida e quem recebe uma contestação. Ao incluir fontes, owners e estados, os estudantes conseguem propor uma solução que pode ser mantida depois da demonstração.

Por fim, uma resposta é rastreável somente quando o percurso pode ser reproduzido com a mesma versão da fonte e política. Guardamos IDs, não necessariamente cópia integral de documentos; metadados permitem localizar evidência autorizada depois. O processo respeita retenção e acesso e oferece informação suficiente para contestar sem criar um novo repositório de dados sensíveis.

Síntese da trilha

Agente analítico organiza investigação, mas não prova causa nem decide legitimidade. A AED continua sendo a cadeia de pergunta, dados, cálculo, visual, narrativa e crítica; o agente atua dentro de ferramentas e limites testados.

No primeiro bloco, o professor desenha no quadro as diferenças entre RAG, GraphRAG, consulta semântica e ferramenta agentic. Os grupos recebem três perguntas e escolhem mecanismo: definição de métrica, comparação numérica e pergunta que combina regra com comparação. Em dez a quinze minutos, desenham arquitetura ponta a ponta e usam IA para sugerir falhas; depois justificam qual ferramenta executa cada etapa e como verificariam o resultado.

O segundo exercício apresenta documentos sintéticos com duas versões de uma regra e uma tabela agregada. A equipe precisa encontrar versão vigente, notar conflito, calcular

uma taxa de exemplo e citar a origem da definição. A resposta de referência explicita que a recuperação documental não calcula a taxa e que o SQL não escolhe sozinho qual regra institucional é válida.

Para tornar o exercício reproduzível, o professor entrega uma pequena ficha de ground truth: definição em vigor a partir de uma data, documento revogado, permissão por perfil e tabela com quatro linhas agregadas. Os grupos assinalam o documento que deve ser recuperado e calculam um numerador/denominador antes de ver a resposta de referência. A comparação expõe se erro veio de recuperar, interpretar ou calcular.

Após a chamada, as equipes fazem um mini trace em papel ou no protótipo: estado inicial, plano, chamada de recuperação, chamada analítica, validação, narrativa e parada. Inserem falha controlada, como fonte sem permissão ou período sem correspondência, e mostram como o fluxo termina. Isso transforma diagrama em sequência de estados que pode virar implementação.

A tarefa de casa continua o storyteller: acrescentar uma definição curta recuperável e responder com ID de evidência, mantendo cálculo em pandas. GraphRAG fica como desenho ou extensão opcional, porque construir e avaliar grafo completo excederia o MVP. O aluno entrega decisão justificada sobre quando a estrutura de grafo agregaria valor, sem fingir que um vetor é um grafo.

A rubrica considera escolha de mecanismo, validade de fonte, cálculo independente, isolamento de ferramentas, tratamento de conflito e comunicação de incerteza. Um fluxo simples que escolhe corretamente entre recuperação e SQL pode superar um agente complexo que não para ou não rastreia fontes. Pontos individuais podem reconhecer quem identifica inferência causal inválida ou risco de acesso.

Durante a apresentação seguinte, um grupo tenta quebrar a solução do outro com uma definição vencida, pergunta multi-hop, métrica numérica ou trecho adversarial. O grupo autor revela que etapa controla a falha, corrige o fluxo e explica se é falha de índice, semântica, consulta, política ou narrativa. A atividade exercita análise de causa de erro, não apenas uso de ferramenta.

O próximo capítulo avaliará a cadeia completa e estabelecerá gates de qualidade. Os traces e cenários deste encontro tornam-se exemplos de teste: cobertura documental, correção de consulta, segurança de ferramenta, visual e resposta final. Cada grupo chega à avaliação com uma arquitetura suficientemente explícita para medir, corrigir ou decidir não implantar.

O fechamento registra também condições que justificariam GraphRAG: volume e dispersão das fontes, relações necessárias, custo de manter entidades e relações, capacidade de corrigir extrações e benefício mensurado sobre recuperação híbrida. Se essas condições não se verificam, a equipe escolhe um catálogo e uma busca mais simples. Essa decisão mostra compreensão de custo de arquitetura, não somente familiaridade com o nome da técnica.

Além de recall e precisão, revisamos diversidade e redundância. Dez trechos quase idênticos podem ocupar top-k sem cobrir definição, vigência e exceção. Uma boa recuperação fornece evidências complementares e mantém origem. O conjunto de avaliação registra qual informação necessária cada documento suporta, o que permite verificar cobertura por aspecto em vez de contar somente trechos pertinentes.

Perguntas compostas podem ter múltiplas subperguntas: qual é a regra, desde quando vale e qual foi a variação observada? A cobertura é medida por componente e pela resposta inteira. Se dois de três componentes têm evidência, o sistema declara lacuna no terceiro em vez de sintetizar resposta completa. Essa avaliação orienta planejamento agentic e

reduz falsa sensação de completude.

Um grafo simples para a aula pode ter nós de métrica, regra, documento, período e curso, com arestas definida_por, vigente_em e ofertado_em. Cada relação aponta a uma fonte e intervalo de validade. Os estudantes verificam manualmente algumas arestas antes da consulta multi-hop, compreendendo que o grafo é modelo de conhecimento, não captura perfeita da realidade.

A busca híbrida pode combinar escore lexical e semântico, mas escala dos escores não é automaticamente comparável. Pesos e reranker são ajustados em dados rotulados e avaliados no conjunto retido. Sem esse trabalho, a palavra híbrida não garante melhor resultado. A equipe registra configuração, idioma, modelo embedding e política de atualização do índice.

Conflito entre fontes exige política. Se uma página institucional vigente contradiz uma apresentação antiga, o sistema pode priorizar fonte de autoridade e data, mas deve preservar o conflito quando não é inequívoco. O LLM não decide autoridade apenas pelo tom do documento. Owner do domínio mantém hierarquia de fontes e processo para desatualizar materiais.

Uma execução agentic deixa claro qual evidência provocou cada passo. Por exemplo, a ausência de definição leva busca ao catálogo; definição localizada autoriza consulta de taxa; consulta devolve sinal de grupo pequeno e encerra para perfil público. Trace com estado e motivos mostra se a decisão de parar foi apropriada, sem exigir que o modelo exponha raciocínio interno privado.

A latência e o custo são medidos também por pergunta respondida, não apenas por chamada. Recuperar cinco vezes pode aumentar chance de cobertura, mas talvez não melhore resposta. Uma comparação informa qualidade, custo incremental e taxa de encerramento. Se mais iteração não muda cobertura do conjunto, simplificamos fluxo ou limitamos busca.

A equipe inclui falhas de atualização e indexação na suíte. Um documento corrigido deve substituir versão anterior conforme política; uma permissão revogada deve refletir-se no índice e cache. Teste mede tempo entre origem e consulta e confirma que documentos obsoletos não aparecem. Operação do RAG é manutenção contínua, não uma etapa única de embedding.

Referências essenciais

- Lewis et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. NeurIPS, 2020.
- Edge et al. *From Local to Global: A Graph RAG Approach to Query-Focused Summarization*. arXiv:2404.16130, 2024.
- Microsoft Research. *GraphRAG: unlocking LLM discovery on narrative private data*.
- OpenAI. *Tools and function calling*. Documentação oficial.