Análise Exploratória de Dados

Capítulo 14 — Avaliação de GenBI

Cayo Oliveira

Sumário

14 Avaliar GenBI: correção, evidência e decisão **3**
14.1 Desenhar um conjunto de avaliação representativo 3
14.2 Medir o funil analítico com denominadores corretos 4
14.3 Auditar consulta, estatística e visual separadamente 5
14.4 Segurança, privacidade, custo e latência como gates 5
14.5 Visualizar resultados e contar uma história auditável 6
14.6 Simulado e fechamento das unidades 7

Capítulo 14

Avaliar GenBI: correção, evidência e decisão

No teste final, dois sistemas respondem que a aprovação aumentou. O primeiro executa SQL válido, mas conta avaliações em vez de matrículas; o segundo calcula taxa correta, mas usa escala gráfica que exagera a diferença e escreve que uma política causou a mudança. Ambos parecem convincentes. A turma precisa avaliar cada camada e decidir qual pode apoiar uma ação.

GenBI combina interpretação, semântica, consulta, cálculo, visualização, narrativa e, por vezes, agente. Uma nota média não localiza erro. A avaliação separa intenção, validade da consulta, correção do cálculo, suporte da evidência, adequação visual, segurança, latência e custo.

Este capítulo aplica competências da Unidade I: distribuição, denominador, escala gráfica, acessibilidade, causalidade, arquitetura, storytelling e governança. O LLM fica dentro de uma análise exploratória, e cada conclusão precisa ser reproduzida por código ou fonte verificável.

14.1 Desenhar um conjunto de avaliação representativo

O conjunto contém perguntas literais, paráfrases, ambiguidade, recusa, comparação temporal, grupo pequeno, perfil sem permissão, dado ausente, consulta sem resposta e pedido causal. Cada caso registra usuário sintético, fonte, definição, período, resultado de referência, visual aceitável e risco.

Uma paráfrase não basta para cobrir diversidade. Se cem perguntas repetem "total do período", o teste não mede composição, anomalia, incerteza, acesso ou recusa. Estratificação dos casos permite estimar onde o produto falha e evita que exemplos simples dominem a média.

O gabarito é independente do sistema avaliado e revisado por especialista de domínio. Cálculos de referência são reproduzíveis; julgamentos visuais usam rubrica; alegações textuais são ligadas a evidência. Um LLM julgador pode apoiar triagem, mas sua concordância é medida contra revisão humana.

Conjunto de desenvolvimento ajuda a ajustar prompts; conjunto retido mede mudança. Um teste em produção acompanha distribuição e incidentes, sem substituir controles offline. Quando resposta de teste é usada repetidamente para ajustar, ela deixa de ser

independente.

O catálogo de casos tem proprietário e data de revisão. Mudança curricular, definição de métrica ou política de acesso exige atualização do conjunto. Casos desatualizados são arquivados com justificativa, sem apagar histórico de avaliação.

14.2 Medir o funil analítico com denominadores corretos

O funil registra perguntas recebidas, autorizadas, interpretadas, consultas aprovadas, cálculos corretos, evidências exibidas e decisões aceitas. A taxa de cada etapa usa denominador declarado; sucesso ponta a ponta divide casos que passaram tudo pelo total elegível.

Se 500 perguntas foram autorizadas, 460 interpretadas corretamente, 420 geraram consulta correta, 390 produziram número correto e 360 mostraram evidência suficiente, as conversões condicionais são 92

Código da squad — taxas do funil com denominador explícito

```
# Registra contagens acumuladas observadas no conjunto sintético.
contagens = {
    "recebidas": 500, "autorizadas": 500, "intencao": 460,
    "consulta": 420, "calculo": 390, "evidencia": 360,
}
# Define a ordem das etapas que compõem o funil de análise.
etapas = ["autorizadas", "intencao", "consulta", "calculo", "evidencia"]
# Usa todas as entradas como denominador da primeira transição.
anterior = contagens["recebidas"]
# Percorre cada etapa na ordem definida pelo protocolo.
for etapa in etapas:
    # Calcula a conversão condicional da etapa atual.
    taxa = contagens[etapa] / anterior
    # Exibe valor, denominador e percentual para auditoria.
    print(etapa, contagens[etapa], anterior, round(taxa * 100, 1))
    # Usa a contagem atual como denominador da próxima etapa.
    anterior = contagens[etapa]
# Calcula sucesso final sobre todas as entradas iniciais.
taxa_final = contagens["evidencia"] / contagens["recebidas"]
# Apresenta a taxa final como percentual arredondado para leitura humana.
print("Sucesso ponta a ponta:", round(taxa_final * 100, 1), "%")
```

O código presume contagens acumuladas e monotônicas. Se cada estágio usa outra população ou amostra, não podemos aplicar a conta sem reconciliar identificadores. A equipe confere logs e cobertura antes de apresentar taxas.

Quando a contagem aumenta ou diminui inesperadamente entre etapas, primeiro reconciliamos o que significa “caso” e se houve amostragem, repetição ou retry. Uma taxa acima de 100

14.3 Auditar consulta, estatística e visual separadamente

Consulta válida não é consulta correta. Revisores comparam SQL à métrica, filtros, grão, datas e joins aprovados. Resultado é conferido com referência determinística e propriedades como taxa entre zero e um, total coerente e contagem sem duplicidade.

O visual é avaliado por correspondência à pergunta, escala, rótulos, ordenação, contraste, incerteza e acessibilidade. Uma coluna truncada pode transformar diferença pequena em grande impressão. Gráfico não deve ocultar denominador ou alterar limites sem anotação.

Storytelling recebe rubrica: pergunta respondida, dado ligado à afirmação, limite explícito, linguagem não causal quando apropriado, ação proporcional e caminho de contestação. Revisores marcam frases específicas em vez de dar apenas impressão geral.

O dashboard de avaliação apresenta erro por camada e segmento. A pessoa identifica se precisa corrigir prompt, definição, consulta, cálculo, visual ou integração. Se tudo vira uma pontuação de "qualidade do agente", a equipe não sabe qual componente melhorar.

Casos críticos aparecem ao lado das médias com identificadores sintéticos e fonte de referência. A revisão visual compara estado inicial e correção aplicada, permitindo observar se escala ou legenda alterou percepção sem mudar dados.

14.4 Segurança, privacidade, custo e latência como gates

Risco de privacidade não é compensado por correção maior. Uma exposição de dado restrito bloqueia a versão. Outros gates definem correção, evidência, p95, custo e recusa. Os limites dependem da decisão e do risco, e recebem aprovação explícita.

Percentis contam a experiência de cauda. Média de dois segundos pode coexistir com p95 de dez segundos. Custo considera entrada, saída, cache, retries e proporção de chamadas. Agentes adicionam passos; instrumentação mede tempo e custo por ferramenta.

Código da squad — gates não compensatórios para versões

```
# Declara critérios mínimos antes de inspecionar versões candidatas.
gates = {"correcao": 0.85, "evidencia": 0.90, "p95": 6.0, "custo": 0.25}
# Registra medições fictícias obtidas no mesmo conjunto de avaliação.
versoes = [
    {"id": "A", "correcao": .88, "evidencia": .92,
     "p95": 5.5, "custo": .24, "vazamento": 0},
    {"id": "B", "correcao": .91, "evidencia": .89,
     "p95": 5.1, "custo": .23, "vazamento": 0},
]
# Seleciona somente opções que passam por todos os gates simultaneamente.
aprovadas = []
# Avalia cada gate de forma independente e conserva apenas aprovados.
for versao in versoes:
    passa = (
        versao["correcao"] >= gates["correcao"]
        and versao["evidencia"] >= gates["evidencia"]
```

```
        and versao["p95"] <= gates["p95"]
        and versao["custo"] <= gates["custo"]
        and versao["vazamento"] == 0
    )
    # Adiciona a versão somente quando nenhum gate crítico falha.
    if passa:
        aprovadas.append(versao)
# Mostra IDs aprovados sem compensar falha com uma média.
print([v["id"] for v in aprovadas])
```

Com esse exemplo, A passa e B falha em evidência apesar da correção superior. Um sistema com vazamento seria reprovado mesmo se outras medidas fossem excelentes. A regra é decisão de governança, não propriedade matemática da média.

Logs guardam versão, trace, resultado da validação, duração e estado com minimização. Conteúdo completo é retido somente quando finalidade e política autorizam. A equipe desenha pausa, rollback, comunicação e reprocessamento para incidente.

14.5 Visualizar resultados e contar uma história auditável

O painel final separa funil, correção, risco, custo, latência e exemplos. Cada cartão tem unidade, período e denominador. Um gráfico mostra sucesso por classe de pergunta e uma tabela abre falhas representativas sem publicar dado pessoal.

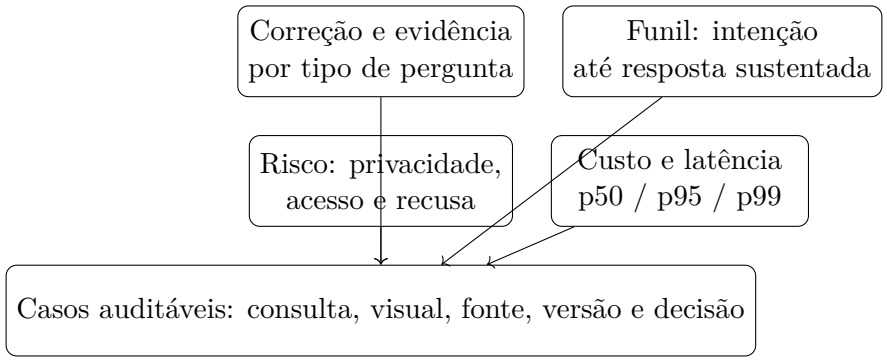

A figura distribui indicadores em quatro domínios e liga todos a casos reproduzíveis. O público não precisa acreditar numa nota agregada: pode abrir amostra, examinar suporte, entender filtro e ver por que uma versão foi aprovada ou bloqueada.

Uma narrativa para liderança pode dizer: “A versão A atende aos gates no conjunto controlado; B tem maior correção média, mas ainda falha em evidência. Não recomendamos B até corrigir a recuperação e repetir o teste retido”. A recomendação comunica ação e condição de revisão.

O painel identifica versão de cada métrica e modelo, período de avaliação e ambiente. Um leitor consegue filtrar por tipo de consulta sem mudar silenciosamente o denominador. A exportação mantém legenda, fonte e nota de limitações.

Na apresentação, a squad conduz a audiência por pergunta, descoberta, evidência e ação recomendada. Primeiro revela o contraste entre correção e evidência; depois abre um caso que falhou e explica o gate; por fim, delimita a decisão operacional. O storytelling organiza a investigação sem esconder incerteza nem transformar correlação em causalidade.

14.6 Simulado e fechamento das unidades

O simulado pede que a squad escolha método, calcule indicador, leia gráfico e defenda limite. Os exercícios praticam conceitos relacionados em cenários e valores próprios; este capítulo não reproduz itens reservados nem gabarito literal.

No fechamento, os estudantes conectam estatística descritiva, probabilidade, associação, gráfico, arquitetura de dados, storytelling, LLM, Text-to-SQL, agentes e avaliação. AED continua responsável por tornar pergunta e evidência visíveis mesmo quando linguagem natural facilita consulta.

O artefato é painel sintético de avaliação, relatório com exemplos, checklist de gate, decisão e plano de próximo teste. A equipe declara o que está pronto para laboratório, o que exige revisão institucional e o que não deve ser implantado.

Cada aluno entrega uma frase de Big Idea e indica o gráfico que melhor a sustenta. A frase é revisada contra denominador, incerteza e perfil de audiência; se a evidência não sustenta a mensagem, narrativa e visualização são refeitas.

A avaliação individual observa também se o estudante consegue reproduzir um cálculo sem o modelo, identificar uma falha de SQL, propor teste retido e explicar quando recusar resposta. A equipe registra a contribuição e o aprendizado, mas não usa dado pessoal para inferir competência além da atividade observada.

Síntese da trilha

GenBI é avaliada como cadeia analítica. A resposta só é confiável quando intenção, métrica, consulta, cálculo, evidência, visual, segurança e operação se alinham; uma média não compensa falha crítica e todo insight precisa ser reproduzível e contestável.